



Facultad de Ciencias
Económicas y Empresariales
UNIVERSIDAD DE MÁLAGA

Trabajo Fin de Máster

Machine Learning Aplicado al Análisis de Riesgo de Crédito

David Felipe Vargas Cadena

Master en Análisis Económico y Empresarial

Curso 2023/2024

Tutor: Julián Molina Luque
Departamento Economía Aplicada (Matemáticas)

DECLARACIÓN DE ORIGINALIDAD

Yo, David Felipe Vargas Cadena con NIE Z1363402J, declaro:

Que este Trabajo Fin de Máster que presento para su evaluación y defensa es original, y que todas las fuentes utilizadas para su realización han sido debidamente citadas en el mismo.

Málaga, a 19 de septiembre de 2024



Firmado: David Felipe Vargas Cadena

Tabla de contenido

| | |
|---|-----------|
| Resumen..... | 4 |
| 1. Introducción..... | 5 |
| 2. Revisión de Literatura..... | 8 |
| 2.1. Generalidades..... | 8 |
| 2.2. El Riesgo de Crédito | 11 |
| 2.3. Machine Learning..... | 14 |
| 2.4. Enfoques Alternativos | 18 |
| 2.5. Riesgos y Limitaciones | 21 |
| 3. Caracterización y Tratamiento de Datos..... | 23 |
| 3.1. Descripción del Conjunto de Datos..... | 23 |
| 3.2. Estadísticos Básicos | 25 |
| 3.3. Tratamiento de Anomalías | 29 |
| 3.4. Impacto del Preprocesamiento | 31 |
| 4. Metodología..... | 34 |
| 4.1. Algoritmo de Búsqueda Local | 34 |
| 4.2. Algoritmo de Cross Entropy..... | 35 |
| 5. Resultados | 38 |
| 5.1. Resultados de Búsqueda Local | 39 |
| 5.2. Resultados de Cross Entropy..... | 41 |
| 5.3. Comparación Entre Enfoques | 43 |
| 6. Conclusiones | 45 |
| 7. Bibliografía | 48 |

Machine Learning Applied to Credit Risk Analysis

Resumen

Este trabajo tiene como objetivo analizar la aplicabilidad de técnicas de *Machine Learning* en el análisis de riesgo crediticio, con un enfoque particular en la selección de variables relevantes y la optimización de modelos predictivos. La revisión de la literatura destaca que estas técnicas superan a los métodos tradicionales en la predicción de riesgos y la reducción de pérdidas. Además, se identifica el reciente interés por la aplicabilidad de enfoques no convencionales basados en métodos Deep Learning que, junto con datos alternativos no financieros, promueve la inclusión financiera. Como metodología, se proponen dos algoritmos de optimización: Búsqueda Local (BL) y Cross Entropy (CE), los cuales se combinan con distintas técnicas de Machine Learning, que tienen como propósito potenciar el proceso que identifica combinaciones óptimas de variables, identificando las más influyentes en la predicción del riesgo crediticio. Los resultados muestran que el preprocesamiento de datos, incluyendo la imputación de valores y la eliminación de *outliers*, es fundamental para aumentar la precisión de los modelos. El análisis comparativo entre BL y CE sugiere que ambos métodos mejoran el rendimiento de los modelos, aunque CE tiende a ofrecer una mayor flexibilidad en la selección de otras variables, obteniendo mejoras adicionales en el proceso de optimización. Además, se encuentra que los retrasos más prolongados en el pago de préstamos se constituyen como los predictores claves del análisis del riesgo.

Palabras clave: Machine Learning, riesgo crediticio, optimización, Búsqueda Local, Cross Entropy, precisión predictiva.

Abstract

This thesis aims to analyze the applicability of *Machine Learning* techniques in credit risk analysis, with a particular focus on the selection of relevant variables and the optimization of predictive models. The literature review highlights that these techniques outperform traditional methods in risk prediction and loss reduction. Additionally, there is a growing interest in the applicability of unconventional approaches based on *Deep Learning* methods, which, together with non-financial alternative data, promote financial inclusion. As methodology, two optimization algorithms are proposed: Local Search (BL) and Cross Entropy (CE), combined with various *Machine Learning* techniques to enhance the process of identifying optimal combinations of variables, focusing on the most influential ones in credit risk prediction. The results show that data preprocessing, including value imputation and outlier removal, is crucial to improving model accuracy. The comparative analysis between BL and CE suggests that both methods improve model performance, although CE offers greater flexibility in selecting additional variables, leading to further optimization improvements. Moreover, it was found that longer loan payment delays are key predictors in credit risk analysis.

Keywords: Machine Learning, credit risk, optimization, Local Search, Cross Entropy, predictive accuracy.

1. Introducción

En las últimas décadas, el entorno económico y empresarial ha experimentado cambios significativos debido al acelerado avance tecnológico, en particular con la revolución digital e informática. Estos avances, impulsados por la explosión de la información, han generado el crecimiento exponencial de lo que conocemos como la Era Digital. Desde mediados del siglo XX, en un contexto marcado por tensiones políticas y económicas recurrentes, los avances en tecnología de la información han dado lugar a una era de innovación sin precedentes, afectando profundamente las estructuras productivas de las empresas, las relaciones entre empresas y consumidores, y las dinámicas competitivas del mercado global. La inteligencia artificial (IA), más allá de su aplicación en robótica e ingeniería, se ha convertido en un elemento clave para el éxito empresarial, permitiendo nuevos modelos de negocio y mejorando la eficiencia de procesos automatizados a través del análisis de grandes conjuntos de datos, caracterizados por las 5 V del Big Data: volumen, variedad, velocidad, veracidad y valor (AEB, 2019).

Con la llegada de la Cuarta Revolución Industrial, el objetivo ha sido integrar de manera generalizada todas las tecnologías disponibles (Nascimento, 2023), lo que exige una preparación proactiva y una rápida adaptación a estos cambios. Según Robert J. Shiller (2016), en el Foro Económico Mundial de Davos: “*No se puede esperar que se queme una casa para comprar un seguro contra incendio. No podemos esperar hasta que haya dislocaciones masivas en nuestra sociedad para prepararnos para la Cuarta Revolución Industrial.*” Esto supone la necesidad de una adaptación temprana a las transformaciones tecnológicas, que afectan a todos los actores económicos y que requieren un alto nivel de flexibilidad para aprovechar las nuevas oportunidades, especialmente en modelos de negocio basados en datos y tecnologías inteligentes, lo que constituye solo una cuestión técnica, sino una estrategia empresarial enfocada en obtener ventaja competitiva.

La explosión en el volumen de datos disponibles ha incrementado la necesidad de aplicar técnicas avanzadas para extraer información útil, posicionando al Big Data como una disciplina clave para la toma de decisiones estratégicas. Las técnicas analíticas avanzadas permiten una mayor capacidad predictiva y analítica para las inteligencias artificiales, transformando la relación entre humanos y máquinas, y potenciando la competitividad de las organizaciones (Cueto, 2019).

El sistema financiero, como uno de los sectores más influyentes en la economía, facilita la

asignación eficiente de recursos a través de la intermediación entre agentes económicos. El mercado de crédito desempeña un papel central en el crecimiento económico al canalizar el ahorro hacia la inversión y el consumo. La transformación digital ha impulsado el surgimiento del sector tecno-financiero, liderado por FinTech y Big Tech, lo que ha contribuido a la expansión del crédito y a la estabilidad financiera, siendo esencial una gestión eficiente, adecuada regulación y precisa evaluación del riesgo de los actores que participan en este mercado (Cornelli *et al.*, 2023; 2020).

Con el desarrollo de algoritmos y modelos que capacita el aprendizaje de patrones y la toma de decisiones, el Machine Learning ha emergido como uno de los pilares de la Inteligencia Artificial (IA), el cual ha tenido un alcance innovador en el sector financiero. El creciente interés por extraer valor de grandes volúmenes de datos ha impulsado importantes inversiones en instituciones financieras, que buscan consolidarse en el ecosistema digital mediante la automatización de procesos en todas sus áreas. Esto ha incrementado la productividad mediante la eficiencia operativa, la detección y prevención de patrones de comportamiento fraudulentos, así como ampliar la comprensión de las dinámicas del mercado a través del análisis de patrones de comportamiento y preferencias de los clientes y en las decisiones de otras entidades competidoras del sector (AEB, 2019).

En el contexto financiero, esta componente de la AI ha contribuido en una amplia variedad de aplicaciones, principalmente reflejado en la capacidad de detección de tendencias integradas en los datos, así como en la optimización del proceso del análisis, calificación y evaluación del riesgo. Aportaciones como en el mercado de activos, donde el Machine Learning se usa ampliamente para proporcionar estimaciones precisas de los precios, estos mismos que por su naturaleza siguen un patrón dinámico aleatorio y no lineal debido a distintos factores (Golbayani *et al.*, 2020). Otro caso corresponde en la gestión comercial de productos y servicios bancarios y de seguros, donde ha contribuido a la segmentación eficiente de grupos demográficos como estrategia de negocio, permitiendo la personalización de portafolios adaptados con mayor precisión a las necesidades y preferencias de usuarios, contribuyendo a la toma de decisiones efectivas entre los agentes. En el ámbito del riesgo en el mercado de bonos corporativos, existe una amplia variedad de estudios centrados en la predicción de incumplimiento y por tanto la calificación de los bonos, donde las evidencias generales indican que las técnicas basadas en la IA superan a las estadísticas tradicionales (Golbayani *et al.*, 2020).

Las técnicas de Machine Learning han cobrado un gran interés en el estudio de la calificación y el riesgo crediticio, generando numerosos aportes académicos en esta área de estudio. La aplicación de estas técnicas a conjuntos de datos complejos y multivariados demuestra un efecto generalizado en el incremento de la capacidad predictiva y el nivel de precisión de los modelos implementados para la medición del riesgo (Gambacorta *et al.*, 2024). Esto ha contribuido a la reducción de falsos positivos y falsos negativos en los procesos de clasificación (AEB, 2019), mejorando el análisis de viabilidad y otorgamiento de crédito, evitando negaciones no justificadas de las solicitudes, así como situaciones financieras imprevistas que limiten la capacidad de pago, y ocasionen sobreendeudamiento e impago (default). Históricamente, la evaluación crediticia dependía de la intuición y experiencia del gerente con el cliente, pero con los actuales modelos empíricos de Machine Learning, es posible una evaluación y clasificación más precisa y consistente basada en datos reales.

En el ámbito financiero, la disruptión tecnológica impulsada por la AI ha permitido desarrollar y optimizar modelos que mitigan el riesgo financiero, mejorando la precisión en la evaluación de la viabilidad crediticia. La búsqueda de mejores niveles de precisión en la predicción del riesgo de futuro impago ha generado especial interés en comprender la interacción entre factores económicos, financieros y sociodemográficos, así como atributos del comportamiento humano capturados a través de dispositivos digitales (Agarwal *et al.*, 2020; Gambacorta *et al.*, 2024; Óskarsdóttir *et al.*, 2019). La capacidad para analizar de manera eficiente esta interacción es clave para que las entidades financieras optimicen sus decisiones, dado el papel crucial del crédito en la economía. Esto ha derivado en la incursión de disciplinas aplicativas como Business Intelligence, que mejora la toma de decisiones al reducir la asimetría de información entre los agentes económicos, favoreciendo una asignación más eficiente de los recursos y contribuyendo al crecimiento sostenible.

Teniendo en cuenta lo anterior, el objetivo principal de este trabajo es identificar y evaluar la aplicabilidad de modelos de Machine Learning y Deep Learning en el análisis del riesgo crediticio. A través de este análisis, se podrán distinguir las diferencias entre las estimaciones generadas por las distintas combinaciones entre algoritmos de optimización y técnicas de Machine Learning, enfocadas en la precisión, desempeño y capacidad predictiva de los modelos. Para este propósito, resulta fundamental identificar las variables que influyen de manera significativa en el riesgo de

crédito, ya que estas determinan la probabilidad de impago. Además, se abordará la metodología aplicada, considerando tanto los modelos empleados como los retos y limitaciones que surgen durante su implementación. Posteriormente, se presentarán los resultados obtenidos, lo que permitirá contrastar las variables más relevantes para cada modelo y facilitar una evaluación crítica de la efectividad de los enfoques utilizados.

El trabajo se estructura con una revisión de literatura que explora conceptos clave como el riesgo crediticio y el Machine Learning, junto con sus enfoques alternativos, limitaciones y riesgos asociados a la implementación de esta tecnología. También se incluye una caracterización y tratamiento de los datos utilizados, describiendo los estadísticos básicos y el proceso de tratamiento previo a la aplicación de las técnicas de Machine Learning, destacando su impacto en los resultados. La metodología se explicará detalladamente, abarcando algoritmos de Búsqueda Local y Cross Entropy. A partir de los resultados, se analizarán la precisión y eficiencia de los modelos propuestos, y finalmente, se ofrecerá una síntesis de los hallazgos principales, evaluando la aplicabilidad de los modelos en el análisis del riesgo crediticio.

2. Revisión de Literatura

2.1. Generalidades

En el contexto económico, y más específicamente dentro del sistema financiero, se puede entender la importancia del factor de la deuda a través del crédito como un instrumento que facilita el intercambio comercial e influye fundamentalmente en la dinámica del consumo, por lo que se convierte en un constante soporte de la actividad económica y determinante de la estabilidad financiera. En el estudio macroeconómico, el nivel de deuda ha resultado explicar la dinámica de los ciclos económicos, tomando relevancia en el análisis de crisis y recesiones económicas, pues desde el punto de vista de la estabilidad financiera, el crédito como instrumento pretende ser una vía de transmisión de perturbaciones entre los agentes económicos (García-Vaquero & Alonso, 2011), a la vez de reflejar decisiones y preferencias de los individuos, los riesgos latentes de impago y los distintos riesgos propios del mercado.

El sistema financiero es uno de los sectores más representativos e influyentes en el estudio de la ciencia económica, el cual agrupa instituciones, mercados y regulaciones, obedecen la lógica

teórica de agente intermediador y facilitador de transacciones entre agentes económicos, con el fin de asignar eficientemente los recursos financieros. Mediante la canalización del ahorro hacia la inversión productiva y el consumo, el mercado de crédito adquiere un papel central en el crecimiento económico, permitiendo que las empresas y hogares accedan al financiamiento. Con el proceso de transformación de este mercado, orientado por las nuevas tecnologías hacia el desarrollo de plataformas digitales, ha dado lugar al surgimiento del sector tecno-financiero liderado por las FinTech y Big Tech. Estas empresas tecnológicas, que llevan a cabo actividades de naturaleza no financieras, han comenzado a incursionar en este tipo de actividad, así como establecer asociaciones con entidades del sector (Cornelli *et al.*, 2023). Esto ha contribuido a la rápida expansión y auge del crédito, estableciéndose una relación causal relevante con el comportamiento del ciclo económico, a la vez de explicar en cierta magnitud la estabilidad financiera y el crecimiento sostenible de la economía (Cornelli *et al.*, 2020). En consecuencia, la gestión eficiente, la regulación adecuada y la evaluación precisa del riesgo de los agentes económicos que interactúan en el mercado de crédito son esenciales.

Con la explosión de la información y la disruptión tecnológica en la era de la 4º Revolución Industrial, el sector financiero ha experimentado una continua transformación sin precedentes. Esta revolución está redefiniendo las metodologías tradicionales para gestionar los instrumentos clave del financiamiento: el préstamo y el crédito; escalando en importancia aún mayor en la dinámica habitual del consumo y en la explicación del crecimiento económico. En este contexto, la integración de AI está potenciando dos aspectos a nivel negocio: internamente, mejorando la competitividad operativa y fortaleciendo la ventaja organizacional al alinear la AI con la cultura empresarial e impulsar la innovación abierta en un mercado altamente competitivo; externamente, impulsa la creación de nuevos modelos de negocio en respuesta a la competencia creciente de actores emergentes como BigTech y FinTech (everis, 2020). Con la liberación de este componente tecnológico, los objetivos clave de nuevos modelos de negocio han pasado a especializarse en el diseño y desarrollo de productos y servicios financieros diferenciados, así como la promoción de interacciones hiperpersonalizadas y experiencias mejoradas para los clientes. Además, el interés por conseguir mejoras en la precisión de la calificación crediticia, frente al masivo volumen de préstamos otorgados por estas tecno-financieras, ha impulsado a invertir y desarrollar en modelos de calificación enfocados en la AI, ya que incluso pequeñas mejoras en esta precisión, puede representar márgenes considerables de ganancias financieras, a la vez de gestionar eficazmente las

exposiciones (Gunnarsson *et al.*, 2021), e incluso maximizar el margen de ganancias, estableciendo cierto nivel de riesgo al retraso del pago por parte del prestatario, permitiendo ser cargado con intereses adicionales (Hand & Henley, 1997).

En los esfuerzos del desarrollo financiero se plantean como objetivo principal la predicción de riesgos mediante el uso distintas fuentes de información financiera, la cual es encontrada en estados financieros y comerciales, así como registros de transacciones y pagos de los usuarios (Yeh & Lien, 2018), resaltando la conveniencia e interés en anteponerse, mitigar y tomar decisiones basadas en los diversos riesgos existentes. Al respecto, en la Encuesta Global de Riesgos (PwC, 2023) realizada a 3.910 empresas líderes de distintos sectores, se revela que las perspectivas de riesgos varían tanto por sector y actividad económica, como por las áreas y dependencias internas de las empresas, donde el 62% de las organizaciones buscan de manera predominante, nuevas oportunidades de crecimiento dentro de los riesgos percibidos. De hecho, el factor de la disponibilidad y aplicabilidad de la tecnología es el que ha configurado mayormente la exposición de las organizaciones a nuevos riesgos, pues encuentran en las herramientas más modernas como la nube y la GenAI, la forma de captar, medir y mitigar el riesgo dentro de sus operaciones, a la vez de incrementar el apetito por la innovación.

En el estudio económico de la incertidumbre, los riesgos financieros relacionados a las perdidas e incumplimientos son de particular interés tanto en tiempos de relativa normalidad, como en tiempos de shocks económicos. La búsqueda comparativa del poder predictivo entre diferentes técnicas pretende hallar los modelos que más se ajusten a la realidad, previendo cualquier tipo de escenario económico. Evidencias como la de Gambacorta *et al.* (2024) sustentan lo anterior, donde se evalúa comparativamente entre un escenario económico normal y otro con shock exógeno negativo en la oferta crediticia agregada para el caso real de una Fintech líder en China en el año 2017, ocasionado por el cambio en la política regulatoria del Banco Popular al emitir un proyecto que endureció las directrices relacionas a la gestión de activos para las instituciones financieras, provocando la contracción de los préstamos y deteriorando de las condiciones crediticias. Los resultados indican que los modelos de calificación crediticia basados en Machine Learning con el uso de datos tradicionales y alternativos, presentan mayor capacidad predictiva de pérdidas e incumplimientos a los modelos empíricos convencionales, en caso de un escenario de mayor incertidumbre a causa de un shock sobre la oferta crediticia.

En la constante búsqueda de extracción de valor dentro del entorno del análisis económico y empresarial, la convergencia interdisciplinar entre la tecnología de la información y la ciencia de la gestión financiera ha dado lugar a un área de investigación con amplio desarrollo en el estudio de la predicción del riesgo o incumplimiento crediticio. Siendo capaz no solo de influir en la evaluación y toma de decisiones para el otorgamiento de préstamos bancarios, el interés por estos aportes de investigación proporcionan indirectamente las bases y puntos de partida a diferentes áreas de investigación que igualmente se relacionan con la toma de decisiones empresariales, principalmente en áreas como el mantenimiento de la cadena de suministro, la inversión en el mercado de bonos y valores e incluso la formulación de políticas económicas gubernamentales (Shi *et al.*, 2024).

Desde la aplicabilidad potencial de la ciencia de datos, técnicas como la minería de datos (Yeh & Lien, 2018), así como la Big Data (Montalvo, 2014), se poseen como los puntos de partida más importantes en cuanto a la extracción y exploración general. Así mismo, desde los fundamentos de la ciencia de redes con el surgimiento de novedosas técnicas basadas en sistemas de relaciones e interacciones complejas, se ha contribuido al aprendizaje computacional a partir de la experiencia, que es propio de la disciplina del Machine Learning. En la práctica, esto ha facultado para la toma de decisiones basadas en la analítica e inteligencia de datos convencional, e incluso ha repercutido de manera desafiante con enfoques alternos de explotación de la información, al proponer técnicas novedosas que distan de las convencionales, junto con conjuntos de indicadores y variables no tradicionales. Con el constante flujo de la información, estas disciplinas pretenden descubrir patrones de comportamiento desde factores significativamente interrelacionados para el análisis predictivo, considerándose funcionalmente útil en las prácticas empresariales para comprender el mismo mercado, con la segmentación de grupos poblacionales de clientes, personalización de productos y servicios, interacción eficaz con el cliente, detección del fraude y amenazas a la ciberseguridad, y calificación crediticia (Yeh & Lien, 2018).

2.2. El Riesgo de Crédito

Conceptualmente, el riesgo de crédito corresponde a la probabilidad de pérdida que tiene un prestatario, dentro de un acuerdo o pacto financiero, de no cumplir con sus obligaciones contractuales, resultando en pérdidas financieras para el prestamista (Caouette *et al.*, 2008). De

manera similar, como concepto se encuentra ligado a la incertidumbre de impago que involucra la capacidad de cumplir una obligación, integrando la probabilidad de que cierta cuantía de capital presente retraso en el reembolso o se considere como pérdida, una vez se ha expuesto a este tipo de riesgo (Hermitaño, 2022); por lo que la debida gestión de este riesgo implica la identificación, evaluación y posterior mitigación mediante diversas estrategias y herramientas basadas en la masividad de datos.

En un panorama más específico, es necesario entender la figura del crédito y el riesgo que este conlleva, no como un instrumento perfectamente uniforme y homogéneo en el sentido de su función y asignación, sino como el conjunto de diversos atributos que configuran un perfil específico de riesgo, reflejado en la tasa de interés. Según García-Vaquero & Alonso (2011), dentro de la economía de España, la importancia del crédito comercial varía según el tamaño de la empresa y la actividad económica, ya que la evidencia sugiere que, para las pymes, así como para las empresas que constituyen el sector de la industria y construcción, les resulta indispensable el acceso al financiamiento a través de este tipo de crédito, en comparación con otro tipo de empresas. Por su parte, la comparativa de Hermitaño (2022) sugiere que, de entre los distintos tipos de riesgos que le compete gestionar a las entidades financieras, el que presenta mayor enfoque e importancia es precisamente el riesgo de crédito, al encontrarse directamente relacionado con la principal fuente de utilidad de esta actividad económica. Debido a esto, al estar relacionado con la variación de pérdidas y ganancias, es en esencia el principal problema que afronta cualquier empresa.

Concerniente a esto, la determinación del riesgo exige posteriormente la fácil interpretabilidad generalizada al establecer una calificación crediticia individual, lo cual es llevado a cabo mayormente por los buros o agencias calificadoras de riesgo. Esta calificación se define en los distintos métodos estadísticos formales que se utilizan para clasificar a los solicitantes de crédito en clases de riesgo “bueno” y “malo” (Yeh & Lien, 2018), y se considera como uno de los primeros campos de la ciencia económica en el que se han aplicado técnicas del Machine Learning (Dumitrescu *et al.*, 2022). De manera similar, en el contexto del crédito corporativo, esta calificación se considera una de las principales claves del cumplimiento de obligaciones, al reflejar el riesgo y confiabilidad de las corporaciones (Golbayani *et al.*, 2020).

Aunque se reconocen las ventajas derivadas, es importante precisar que la aplicabilidad de los distintos modelos predictivos a través de este enfoque plantea convenientemente la idea de que su

implementación individual no proporciona comparativamente las mismas estimaciones ni certezas acerca del riesgo crediticio. Esto sugiere que los métodos difieren en aspectos como la arquitectura del modelo, cantidad de datos, capacidad de generalización y tiempo de entrenamiento (Shi *et al.*, 2022); lo que induce la idea acerca sobre como la capacidad analítica y predictiva de cada modelo genera distintos resultados e interpretaciones sobre el riesgo, y por lo tanto influye distintivamente en la toma de decisiones al momento de estimar la viabilidad y otorgamiento del crédito.

Distintos aportes a la literatura relacionada precisan al ecosistema financiero como uno de los segmentos económicos con mayor potencial aplicación de la AI, ya que tiene el atributo de generar constantemente gran cantidad de datos, definiendo la naturaleza cuantitativa de la propia actividad y capacitando la integración de esta tecnología. Del mismo modo, fuentes privadas encargadas de la recopilación de información crediticia, encuentran que, entre los distintos tipos de crédito, el destinado al consumo representa la principal fuente de información de usuarios, al representar una parte considerable de las solicitudes a las entidades financieras y su relativa mayor rapidez en el proceso que lleva al otorgamiento, esto en comparación con otras clases de crédito como el empresarial e interbancario. De hecho, según el Banco de España (2024), a pesar del endurecimiento de los criterios de concesión por parte de las entidades y el descenso generalizado del volumen de crédito, la demanda de crédito al consumo ha mantenido una mayor estabilidad que otras modalidades, incluso demostrando ser uno de los pocos segmentos con crecimiento, que para el 2023 fue del 2.9% (Olano, 2024), convirtiéndolo en parte esencial de la cartera de las entidades prestamistas.

La proliferación de estrategias impulsadas por los neobancos del naciente sector tecno-financiero (Fintech y BigTech), enfocadas en productos y servicios digitales especializados en tarjetas de crédito y micro préstamos inmediatos (Experian, 2021), han establecido una posición de liderazgo en el mercado, producto de convertir al crédito de consumo en una masiva industria con directa influencia económica (Gunnarsson *et al.*, 2021). Además, estos novedosos modelos de negocio se distinguen a nivel operativo por la minimización de requisitos en la solicitud, rapidez en el proceso de otorgamiento, montos de desembolso no muy altos, reembolsos en plazos cortos, y muchas veces con tasas de interés más atractivas que los micro préstamos ofrecidos por la banca tradicional (Óskarsdóttir *et al.*, 2019).

Aunque la generación de datos comienza principalmente con el proceso de solicitud de crédito, no

termina con el otorgamiento de este. En la industria bancaria, la posterior recopilación de información mediante el monitoreo continuo del comportamiento de pago es necesaria no solo para llevar a cabo la gestión estratégica de mitigación de perdidas por parte de cartera, sino que además es la piedra angular del desarrollo descriptivo y predictivo de la inteligencia y analítica de negocios. Esto plantea una exigencia en los procesos de ETL (en inglés Extract, Transform and Load), que garanticen la aplicabilidad de la ciencia de datos en entornos económicos y empresariales, contribuyendo de manera significativa aspectos clave de los datos: la fuente y calidad, su exploración y análisis, el modelado y la predicción, así como la evaluación, validación, interpretación y comunicación de los resultados (FasterCapital, *sf*).

2.3. Machine Learning

Con la extensa literatura relacionada al estudio de los principales componentes del estudio de la AI, se ha evaluado la pertinencia, así como el impacto de los distintos métodos del Machine Learning sobre la analítica de riesgo de crédito. A primera vista, pretende ser indiscutible el efecto positivo sobre la innovación y productividad empresarial que se refleja en la identificación de clientes de alto riesgo, al evidenciarse en la mayoría de los estudios cierta reducción de pérdidas económicas por efectos del impago, alcanzando un ahorro potencial de entre el 6% y 25% (Khandani *et al.*, 2010). De acuerdo con Lessmann *et al.* (2015), al llevar a cabo una comparación exhaustiva entre 41 clasificadores con respecto a 6 medidas de rendimiento de técnicas de Machine Learning, se encuentra que los modelos de clasificación basados en Random Forest, Neural Networks (NN) y XGBoost (Extreme Gradient Boosting), superan a métodos tradicionales como los modelos de regresión logística o discriminación lineal, al reducir costos en la predicción de errores de clasificación, además de su facilitar su aplicabilidad en grandes volúmenes de datos. Además, el estudio recomienda que el área bajo la curva (AUC), mediante la característica operativa del receptor (ROC), el Gini parcial y el puntaje Brier, como referencias para llevar a cabo la medición del rendimiento de predicción de los algoritmos clasificadores (Gunnarsson *et al.*, 2021).

La automatización de decisiones más precisas permite la posibilidad de democratizar el acceso, la cobertura y el uso de servicios financieros, lo que reduce los prejuicios negativos en el proceso de análisis y otorgamiento, y promueve la inclusión financiera que en principio es necesaria en

hogares vulnerables, grupos sociodemográficos específicos y pymes; pues estos suelen presentar limitaciones relacionadas a altos costos para establecer conexiones comerciales, distancia física a centros de atención y falta de documentación adecuada para la gestión de riesgo (Huang, 2023). Al respecto, las evidencias de Fuster *et al.* (2021) acerca de la implementación de algoritmos de Machine Learning en el mercado de hipotecas de EE.UU y su efecto en la distribución préstamos y tasas de interés entre diferentes grupos demográficos, señalan que las Fintech - en comparación con los bancos tradicionales - operan de manera más eficiente en la provisión de crédito hipotecario, al ser capaces de procesar la información un 20% más rápido, influyendo positivamente en la percepción del servicio y experiencia de usuario. Sin embargo, también se evidencia que la implementación de esta tecnología puede exacerbar las disparidades en las predicciones del mercado crediticio entre los diferentes grupos demográficos, pues a través del aprendizaje propio del algoritmo, se podría aumentar la desigualdad en la inclusión financiera y generar intencionalmente predicciones de riesgo discriminatorias entre grupos raciales y étnicos, afectando la igualdad del acceso al crédito.

Varios antecedentes de investigaciones relacionadas sugieren que los algoritmos propios de este subcomponente de la AI, tales como Random Forest, Gradient Boosting y Deep Neural Network (DNN) ofrecen un mayor valor en la gestión de riesgos al evidenciar ganancias en la precisión y rendimiento de hasta el 20% (Alonso-Robisco & Carbo, 2023), con respecto a otros métodos estadísticos tradicionales. Aun teniendo en cuenta que ambas metodologías comparten el objetivo de generar predicciones a partir del entrenamiento de algoritmos, contrario a lo esperado, los algoritmos más complejos de la AI que en la literatura son catalogados como componentes de la Deep Learning, a saber los derivados de Neural Networks (NN), no siempre generan mejores predicciones dentro de los modelos de riesgo, sugiriendo en muchos casos que los modelos basados en técnicas de Decision Tree, Random Forest o XGBoost, presentan un mejor rendimiento predictivo (Alonso-Robisco & Carbo, 2023). Según las evidencias de Gunnarsson *et al.* (2021), donde se comparan las distintas técnicas de clasificación, el método XGBoost supera en rendimiento a otras técnicas consideradas. De entre estas, los modelos NN con redes de varias capas ocultas de profundidad (DNN) considerados de Deep Learning, no llegan a superar en rendimiento a otros menos profundos con única capa oculta. Estos últimos también presentan un mayor costo computacional en comparación con otros clasificadores del Machine Learning para la calificación crediticia, demostrando que los algoritmos de Deep Learning, aparte de su compleja

construcción e interpretación, podrían no ser los métodos más apropiados para la calificación crediticia (Gunnarsson *et al.*, 2021).

Por su parte, la revisión realizada por Yeh & Lien (2018), se centra en el caso de los pagos de clientes titulares de tarjetas de crédito de un banco Taiwán en el año 2005, en el que se utilizan variables explicativas de tipo sociodemográficas, relacionadas con el historial de pagos y de estados de cuentas. Mediante la comparación del rendimiento de la clasificación y la precisión predictiva entre los métodos de Análisis Discriminante, Regresión Logística, Clasificador de Bayes, Nearest Neighbor, Artificial Neural Networks (ANN), y Classification Trees; se encuentra que el método de ANN ofrece mayor precisión en la clasificación, así como en la precisión predictiva de la probabilidad de incumplimiento; sugiriendo además que en cuanto a control de riesgos, resulta más significativo la estimación de la probabilidad de impago que la clasificación binaria de los clientes entre riesgosos y no riesgosos (Yeh & Lien , 2018).

Basado en la problemática de la interpretabilidad de la mayoría de los métodos del Machine Learning, la propuesta de Dumitrescu *et al.* (2022) parece reconciliar la simplicidad explicativa de los modelos de regresión logística con el potencial de predictores de Decision Tree de corta profundidad y un método de estimación penalizado. Proponiendo un enfoque híbrido de Regresión de Árbol Logístico Penalizado (PLTR por sus siglas en inglés), los autores buscan mejorar el rendimiento predictivo y conservar la interpretabilidad de los modelos de calificación crediticia, realizando una comparación con varias metodologías de referencia sobre cuatro bases de datos populares de la plataforma Kaggle. Aunque dentro del contexto regulatorio de las finanzas, se considera este modelo alternativo como desafiante, las evidencias sobre el PLTR demuestran que supera en precisión predictiva a la regresión logística lineal y no lineal tradicional, así como al método de Random Forest, además de contribuir al beneficio económico en la reducción significativa de los costos de clasificación errónea y el análisis de beneficio máximo esperado (Dumitrescu *et al.*, 2022).

Considerando el riesgo crediticio en el caso de las pymes, Gu *et al.* (2024) implementan un conjunto de 20 variables provenientes de 811 empresas, que abarca datos financieros, información de micro comportamiento empresarial, registros crediticios públicos e información obtenida de terceros. Los autores encuentran en su mayoría, que las variables del conjunto de información financiera convencional son relevantes en la evaluación del riesgo crediticio, mientras que los otros

conjuntos de información no financiera se pueden considerar como complementaria (Gu *et al.*, 2024). A través de un enfoque combinado entre el algoritmo SMOTE y el modelo de tarjeta de puntuación XGBoost para la identificación y precisión de características críticas, se obtienen resultados de clasificación más efectivos y por lo tanto mayor precisión predictiva, en comparación con otros modelos como Decision Tree, Random Forest y Support Vector Machine (SVM). Adicionalmente, se recomienda abordar con un enfoque dinámico a los casos restantes de pymes con puntajes crediticios medios y bajos, así como se enfatiza los posibles beneficios de criterios financieros más relajados a pymes con puntajes altos.

De entre los tipos de crédito, el análisis del riesgo crediticio corporativo presenta diferencias sistemáticas con respecto a los demás tipos, pues por su naturaleza tiene el atributo de la disponibilidad limitada de datos masivos, lo que plantea un reto en la aplicabilidad técnica para la estimación del riesgo y la calificación de crédito. Según Golbayani *et al.* (2020), aunque el riesgo de bonos y crédito estén relacionados dentro del el ámbito corporativo, la negociación de bonos permite ajustes frecuentes al mercado en comparación con las calificaciones corporativas basadas en informes financieros trimestrales. Debido a esto y a la variabilidad en la estructura de los estados financieros entre diferentes sectores, las investigaciones previas generalmente han construido modelos específicos de riesgo y calificación de crédito para cada sector.

Basados en la aplicabilidad previa de técnicas del Machine Learning en variables financieras históricas, Golbayani *et al.* (2020) consideran un conjunto de datos de 52 acciones del sector financiero, 28 acciones del sector energético y 44 acciones del sector sanitario entre 1990 y 2018, en el que se seleccionan las variables más relevantes según su relevancia en la calificación crediticia que se han tomado de S&P. Con los resultados del rendimiento entre las técnicas de Bagged Decision Tree (BDT), Random Forest, Multilayer Perceptron (MLP) y Support Vector Machines (SVM); se evidencia que las técnicas BDT y Random Forest no solo superan consistentemente a las MLP y SVM en precisión predictiva, sino además ofrecen mayor captura a los cambios en las calificaciones crediticias. Con lo anterior, y basado en la Notch Distance propuesta por los autores, se calcula la distancia de las calificaciones para las mismas empresas, que se han otorgado por las agencias S&P, Moody's y Fitch. Los autores concluyen que los métodos basados en Decision Tree generan predicciones tan precisas, que las desviaciones en sus calificaciones son similares a las discrepancias que existen naturalmente entre las distintas agencias de calificación.

Si bien se reconoce que en los modelos actuales de calificación crediticia impera las técnicas derivadas de Decision Trees, incluso por encima de la tradicional Logistic Regression, las evidencias obtenidas mediante la propuesta de Clements *et al.* (2020) demuestran las aparentes limitaciones de esta técnica, pues el rendimiento de modelos dependen indirectamente de la experiencia en el dominio que derivan a la ingeniería de nuevas variables, falta de aprovechamiento de datos históricos y problemas de la aplicabilidad en entornos de aprendizaje en línea. Usando datos tabulares de transacciones de tarjetas de crédito de 15 millones de miembros, abarcando un período de doce meses, se crearon 45 millones de secuencias al desplazar la ventana temporal un mes y repitiendo dos veces esto mismo, con el fin de mejorar el conjunto de datos de entrenamiento. La metodología propuesta involucró el uso de redes neuronales profundas secuenciales, específicamente con la técnica de Temporal Convolutional Networks (TCN), para ser comparada con el modelo de producción basado en Gradient-Boosted Decision Tree (GBDT). Los resultados sugieren que el TCN, combinado con el método de muestreo propuesto por los autores, superó al modelo basado en GBDT en términos de ahorro financiero y detección temprana del riesgo crediticio, además de facultarlo como un enfoque apto para ser implementado en un entorno de producción y para el aprendizaje en línea.

2.4. Enfoques Alternativos

Una nueva dinámica fragmenta el panorama del análisis del riesgo actual entre los métodos convencionales y los guiados a las nuevas tecnologías con información alterna. Recientemente se ha incursionado en formas alternativas de analizar el riesgo de crédito, ya sea desde nuevas metodologías, como desde distintos tipos de datos como punto de partida. Estudios recientes se encuentran enfocados en considerar fuentes de datos menos tradicionales y un tanto alejados de la información financiera, como los datos no estructurados que se constituyen de imágenes, textos o huellas móviles; con el fin de mejorar el rendimiento de los algoritmos implementados para la calificación y riesgo crediticio. Por otro lado, la perspectiva del riesgo actual es distinta entre sectores, e influye en las metodologías aplicadas para la analítica del riesgo, como puede ser en el caso de grandes corporaciones y pymes. Mientras que, en la banca tradicional, a las grandes corporaciones solicitantes de crédito se les valora por la información relacionada al historial financiero, activos colaterales e información confidencial; a las pymes solicitantes resulta de mayor

valor la pignoración de activos como garantía de un crédito (Huang *et al.*, 2023). Esto dificulta el acceso al financiamiento para las empresas que no poseen este tipo de activos que sirvan como garantía del financiamiento, lo que ha planteado la necesidad de un enfoque alterno no estrictamente dependiente de datos financieros (Agarwal *et al.*, 2020).

En el aspecto generacional de la población, las evidencias de Agarwal *et al.* (2020) acerca de la inclusión financiera y modelos alternos de scoring, se basan en datos provenientes de una plataforma de préstamos Fintech de la India en el 2016, que agrupa variables financieras, historial crediticio y de huellas móvil, social y digital (datos extraídos del uso de teléfono móvil, ubicación, así como actividad, interacción y contactos en redes sociales). Con esta información se implementan modelos basados en Regresión Logística, Random Forest y XGBoost. Los hallazgos obtenidos, que también concuerdan con las evidencias de Gambacorta *et al.* (2024) en el caso de una Fintech en China, sugieren que los modelos de Machine Learning aplicados con los datos alternativos o no financieros que provienen de huellas móvil, social y digital, no solo mejorarían la precisión en la evaluación del riesgo, sino que además tienen el potencial de expandir el acceso al crédito para grupos generacionales e inmigrantes sin experiencia crediticia, desatendidos por la banca tradicional y no susceptibles a los métodos convencionales de calificación y perfilación crediticia.

Siguiendo esta línea, Óskarsdóttir *et al.* (2019) implementan datos recopilados por un operador de telecomunicaciones y un banco comercial que operan en el mismo país, principalmente provenientes del uso propio de teléfonos por parte de clientes. Basado en el rendimiento (AUC) de varias combinaciones propuestas de modelos con los clasificadores de Logistic Regression, Decision Tree y Random Forest, se demuestra que la incorporación de datos de telecomunicaciones como los CDR (en inglés Call Detail Record), tiene el potencial de aumentar el valor de los modelos de calificación crediticia en términos estadísticos, lo que representa una fuente suficiente de datos para la decisión positiva o negativa del otorgamiento de crédito. En este mismo contexto, el enfoque K-Nearest Neighbors (KNN) y Graph Neural Networks (GNN) propuesto por Shi *et al.* (2024) utiliza un método integrado de aprendizaje de representación en grafos para mejorar la predicción del riesgo crediticio. Este enfoque construye grafos mediante el método de k-Nearest Neighbors (KNN) que define conexiones entre instancias, para luego aplicar (GNN) con el fin de clasificar los nodos según su riesgo de crédito, demostrando ser significativamente más preciso en

la predicción del riesgo en comparación con las técnicas convencionales de clasificación.

El alcance de la cobertura de préstamos a las pymes ha sido gestionado de forma más eficiente por plataformas digitales bancarias como las Fintech y BigTech, al encontrar una oportunidad de crecimiento en el segmento de clientes desatendidos por la banca tradicional. Según Huang *et al.* (2023), el enfoque BigTech basado en modelos de Big Data y el Machine Learning a partir de datos en tiempo real, ha permitido el procesamiento masivo de solicitudes, actualización dinámica de las evaluaciones de riesgo y reestructuración de préstamos en grandes volúmenes. Con un conjunto de 1.8 millones de datos de préstamos otorgados a pymes entre marzo y agosto de 2017 por parte de MYbank - uno de los bancos virtuales líderes en China -, los autores analizan 76 variables sobre las características agrupadas de las empresas en dos categorías: datos tradicionales correspondiente a información financiera, de propiedades, historial crediticio y sociodemográfica del proveedor; e información patentada correspondiente a volumen de transacciones y huellas digitales (principalmente patrón de consumo en línea). En este estudio, se compara el poder predictivo de 4 modelos evaluados por el método de Scorecard y el método de Random Forest, cada uno aplicado a información únicamente tradicional y a toda la información (tradicional y de patente). La evidencia sugiere que entre el enfoque BigTech, correspondiente a la aplicación del Machine Learning sobre información tradicional y patente; y el enfoque bancario, correspondiente al método Scorecard con información únicamente tradicional, el BigTech presenta una ventaja significativa al implementar el total de información con métodos de Machine Learning en el análisis de riesgo de crédito, incrementando el desempeño de los modelos para la predicción de la probabilidad de impagos (Huang *et al.*, 2023).

Con la exploración de datos no financieros para modelar el riesgo de crédito de manera alternativa, se ha identificado un enfoque de estudio fructífero que reexamina la resolución de problemáticas, alentando a la investigación del riesgo a través de la integración de otros campos de estudio que pretenden estar interrelacionados. Los avances recientes de la ciencia de redes en el campo de estudio del riesgo han comprobado que la probabilidad de default se encuentra interrelacionada entre agentes cercanos y que interactúan en el mercado financiero. Mayormente enfocado en el análisis de propagación del riesgo entre grandes instituciones financieras, Bookstaber & Kenett (2016) se basan en la metodología de Multilayer Network para ilustrar un mapa donde los riesgos se originan y se propagan de manera sistemática debido a las interconexiones entre capas,

representadas en las transacciones de financiamiento a corto plazo, flujos de colaterales y activos. Esto expone la vulnerabilidad y vías de contagio del riesgo, el cual se transforma a medida que se mueve entre capas, demostrando que un choque de precios se puede transformar en un riesgo de financiamiento, para luego expresarse en un riesgo de crédito, que a su vez conlleva en un riesgo de liquidez (Bookstaber & Kenett, 2016).

Ahora bien, basándose en esta lógica de propagación en redes para la evaluación del riesgo crediticio, Óskarsdóttir & Bravo (2021) proponen un modelo de Multilayer Network con una medida de centralidad Page Rank, usando como variables conectoras la ubicación geográfica y la actividad económica de cada uno de los prestatarios, permitiendo crear una red interconectada de datos que aparentemente no muestran tener una clara relación en el contexto de préstamos agrícolas. Los resultados sugieren que los modelos de scoring crediticio creados que utilizan variables de red, además de las tradicionales, muestran un incremento significativo en su rendimiento predictivo de default, destacando entre estas las variables de comportamiento como las más relevantes. Además, se corrobora que los enfoques multicapa son más útiles que los de una sola capa, a la vez de enfatizar la importancia acerca de cómo el riesgo de default se propaga a través de las redes y expone al riesgo a los prestatarios sanos y cierta manera los más cercanos a los ya contagiados, lo que contribuye a la toma de decisiones preventivas en la gestión de cartera. Con este trabajo, se demuestra como alternativa plausible y de interés, la exploración del riesgo y calificación crediticia mediante Deep Learning, implementando técnicas como la Graph Neural Networks (GNN).

2.5. Riesgos y Limitaciones

La necesidad de comprender la funcionalidad de los algoritmos de principio a fin genera dudas recurrentes sobre el uso de métodos de Machine Learning en la calificación crediticia. Una de las principales limitaciones de estos métodos radica en la dificultad de su aplicabilidad e interpretación generalizada. En la práctica, hacer que un modelo supervisado sea más complejo de lo necesario ocasiona sobreajuste, provocado por ajustar estrechamente el modelo a los datos de entrenamiento, evitando la correcta generalización a los nuevos datos para realizar predicciones, por lo que es indispensable ajustar los datos tanto de la forma correcta como de la forma más sencilla posible. A menudo se les considera "cajas negras" en la literatura, ya que el proceso de aprobación o

calificación crediticia no es fácilmente explicable para los clientes y reguladores financieros (Dumitrescu *et al.*, 2022). Esto explica por qué las metodologías tradicionales como la regresión logística, imperan como el enfoque estándar en los procesos de evaluación del riesgo, pues ofrecen estabilidad, robustez y simplicidad en la interpretación de la lógica de la medición del riesgo. Debido a esto, en los últimos años el campo de estudio de la AI ha percibido un creciente desarrollo del subcampo de la AI explicable (XAI), la cual tiene como objetivo el desarrollo de métodos para volver interpretables los modelos de “caja negra”.

Sabiendo del potencial de la IA, son previsibles los riesgos asociados a la implementación de esta tecnología, resumidos desde la pertinencia y estabilidad predictiva, pasando por la transparencia de los algoritmos, hasta la privacidad de los datos. Esto exige plantear ciertas recomendaciones, limitaciones y regulaciones sensatas que, según Alonso-Robisco y Carbo (2023), citando a Floridi *et al.*(2022), exponen:

En este sentido, el enfoque regulador trata de evaluar el riesgo asociado al uso de sistemas basados en IA a través de la evaluación del potencial impacto negativo para los usuarios de los mismos. Así, bajo la pionera Directiva de Inteligencia Artificial propuesta por la Comisión Europa (legislación conocida como AI Act) un recomendador automático de productos de inversión o un chatbot para la interacción con los clientes no tendría tanto impacto potencial negativo como un sistema de evaluación de riesgo crediticio (credit scoring), cuyas potenciales decisiones de denegación de un préstamo pueden dañar la solvencia de empresas e individuos. En este último caso se establece como prioritario la gestión del riesgo de modelo, y el buen gobierno de la tecnología, existiendo el requerimiento de cumplir con un test de conformidad regulatorio. (p. 81)

Los diferentes tipos de datos son susceptibles de ser enmarcados para un uso específico, lo que conlleva a su tratamiento directo y por lo tanto al riesgo de manipulación e inestabilidad. Basados en el origen poco convencional, los riesgos inherentes al enfoque alternativo del riesgo de crédito se relacionan con la posible manipulación y falsificación de los datos de huella digital para influir o alterar en la obtención de mejores puntajes crediticios (Agarwal *et al.*, 2010). No muy distinto a esto, el fraude o robo de identidad para obtener productos y servicios financieros, se contextualiza en la banca digital, donde la oferta de micro préstamos inmediatos se vuelve un objetivo, ante la capacidad de obtener, usar y combinar información real con sintética. Además, las preocupaciones a nivel ético que implica el riesgo a la privacidad y seguridad de la información personal, ya que los datos se generan a partir del uso de dispositivos personales y, en el proceso, son compartidos

entre diferentes entidades. Dependiendo de la legislación nacional, estas entidades pueden estar autorizadas a transferir información a otras entidades bajo un contrato, como es el caso de EE.UU. con la Ley Gramm-Leach-Bliley (Óskarsdóttir *et al.*, 2019), lo que aumenta potencialmente el riesgo a la privacidad y seguridad de la información personal.

Por otro lado, el riesgo asociado al uso de la información para la toma de decisiones puede materializarse de forma imperceptible e incluso no premeditada en cualquier escenario. Tal como lo expone Fuster *et al.* (2021), es probable que la IA a través del Machine Learning implementado en bancos y demás entidades financieras, terminen por realizar predicciones sesgadas y racialmente discriminatorias, aunque de manera no intencionada en cuanto al otorgamiento de crédito. Debido a la forma de aprendizaje del algoritmo con respecto a la distribución de los datos para su entrenamiento, resulta en favorecer principalmente a los prestatarios blancos no hispanos y asiáticos con respecto al resto. Como evidencia del polémico enfoque de entrenamiento de modelos con información demográfica y personal en la práctica financiera, varios estudios como los realizados por Fuster *et al.* (2021) o Clements *et al.* (2020) recomiendan no incluir variables de este tipo en la implementación del Machine Learning, en aras de garantizar la equidad en el análisis y otorgamiento de crédito. Al respecto, un caso real relacionado con la existencia del sesgo oculto en el proceso de inferencia ocurrió con el sistema de automatización en las decisiones de contratación laboral de Amazon, pues hasta el 2018 la multinacional implementaba un algoritmo de clasificación que favorecía a los candidatos hombres por encima de las mujeres. De manera similar, el algoritmo aprendió al observar los patrones de los currículums enviados durante un periodo de 10 años, en donde la mayoría de los solicitantes eran hombres y por lo tanto preferibles para el sistema, penalizando automáticamente la calificación de los perfiles femeninos (Sáez, 2020; Dastin, 2018).

3. Caracterización y Tratamiento de Datos

3.1. Descripción del Conjunto de Datos

En el presente trabajo se ha implementado la popular base de datos **Give Me Some Credit**, proveniente de la plataforma Kaggle, la cual se especializa en competencias de Machine Learning a nivel mundial. Esta base de datos, propia de un concurso aplicado al Credit Scoring en el año

2011, ha sido ampliamente usada en la investigación académica como base de entrenamiento y testeo de las distintas técnicas de Machine Learning y Deep Learning, además de ser clave para fines comparativos de novedosas propuestas y métodos algorítmicos que derivan de los esfuerzos por incrementar la precisión y rendimiento de sus resultados.

La base de datos original contiene información de más de 250.000 datos sobre préstamos al consumo anónimos, que se divide en 150.000 préstamos como conjunto de entrenamiento etiquetado, además de contener el conjunto de prueba de 101.503 filas sin etiqueta. En la Tabla 1 se describe detalladamente cada una de las variables del conjunto de datos.

Tabla 1. Descripción de variables

| Variable | Descripción | Tipo |
|--|--|-----------------------------------|
| SeriousDlqin2yrs | El prestatario se encuentra en impago o retraso por 90 días o más en el pago de la cuota. | Cuantitativa Dicotómica |
| RevolvingUtilization OfUnsecuredLines | Saldo total en tarjetas de crédito y líneas de crédito personales, excepto bienes raíces y deuda sin cuotas como préstamos de automóviles, dividido por la suma de los límites de crédito. | Cuantitativa Continua |
| Age | Edad del prestatario en años. | Cuantitativa Discreta |
| NumberOfTime30-59 DaysPastDueNotWorse | Número de veces que el prestatario ha tenido un retraso únicamente entre 30-59 días en el pago, en los últimos 2 años. | Cuantitativa Discreta |
| DebtRatio | Pagos mensuales de deuda, pensión alimenticia y costos de vida divididos por el ingreso bruto mensual. | Cuantitativa Continua |
| MonthlyIncome | Ingreso mensual del prestatario. | Cuantitativa Continua |
| NumberOfOpenCredit LinesAndLoans | Número de préstamos abiertos (a plazos, como préstamos de automóviles o hipotecas) y líneas de crédito (por ejemplo, tarjetas de crédito). | Cuantitativa Discreta |
| NumberOfTimes90 Day Slate | Número de veces que el prestatario ha tenido un retraso de 90 días o más en el pago de la cuota. | Cuantitativa Discreta |
| NumberRealEstate LoansOrLines | Número de préstamos hipotecarios y de bienes raíces, incluidas líneas de crédito con garantía hipotecaria. | Cuantitativa Discreta |
| NumberOfTime60-89 DaysPastDueNotWorse | Número de veces que el prestatario ha tenido un retraso únicamente entre 60-89 días en el pago de la cuota, en los últimos 2 años. | Cuantitativa Discreta |
| NumberOfDependents | Número de dependientes en la familia, excluyendo al propio prestatario (por ejemplo, cónyuge, hijos, etc.). | Cuantitativa Discreta |

Fuente: Elaboración propia con base en el conjunto de datos “Give Me Some Credit”

Dentro del conjunto de datos de entrenamiento se encuentra la variable objetivo **SeriousDlqin2yrs**, junto con 10 variables explicativas que corresponden a algunas de las características financieras y atributos individuales de clientes. La variable objetivo se encuentra definida de forma dicotómica y corresponde a la etiqueta del estado de cada préstamo, indicando si este se encuentra en situación de impago (default) en 90 días o más.

3.2. Estadísticos Básicos

Al examinar los estadísticos descriptivos de cada variable, se evidencia una distribución similar de valores atípicos y patrones irregulares en ambos conjuntos de datos. Las Tablas 2 y 3 muestran un resumen detallado de los estadísticos descriptivos para estas variables en ambos conjuntos de datos.

Tabla 2. Estadísticos descriptivos del conjunto de entrenamiento

| Variable | Count | Mean | Std | Min | 25% | 50% | 75% | Max |
|--------------------------------------|--------|--------|----------|-----|-------|-------|-------|---------|
| SeriousDlqin2yrs | 150000 | 0,067 | 0,25 | 0 | 0 | 0 | 0 | 1 |
| RevolvingUtilizationOfUnsecuredLines | 150000 | 6,048 | 249,75 | 0 | 0,03 | 0,154 | 0,559 | 50708 |
| Age | 150000 | 52,295 | 14,77 | 0 | 41 | 52 | 63 | 109 |
| NumberOfTime30-59DaysPastDueNotWorse | 150000 | 0,421 | 4,19 | 0 | 0 | 0 | 0 | 98 |
| DebtRatio | 150000 | 353,01 | 2037,81 | 0 | 0,175 | 0,367 | 0,868 | 329664 |
| MonthlyIncome | 120269 | 6670,2 | 14384,67 | 0 | 3400 | 5400 | 8249 | 3008750 |
| NumberOfOpenCreditLinesAndLoans | 150000 | 8,453 | 5,14 | 0 | 5 | 8 | 11 | 58 |
| NumberOfTimes90DaysLate | 150000 | 0,266 | 4,16 | 0 | 0 | 0 | 0 | 98 |
| NumberRealEstateLoansOrLines | 150000 | 1,018 | 1,13 | 0 | 0 | 1 | 2 | 54 |
| NumberOfTime60-89DaysPastDueNotWorse | 150000 | 0,24 | 4,15 | 0 | 0 | 0 | 0 | 98 |
| NumberOfDependents | 146076 | 0,757 | 1,11 | 0 | 0 | 0 | 1 | 20 |

Fuente: Elaboración propia según resultados obtenidos con Python 3.12.1

Considerando algunos descriptivos del conjunto de datos original de entrenamiento (ver Tabla 2) y de prueba (ver Tabla 3), se encuentra que:

- La variable objetivo **SeriousDlqin2yrs** tiene una media de aproximadamente el 6.7%, indicando la proporción de prestatarios que han incurrido en impagos. Esta proporción

sugiere un desequilibrio significativo en las clases (impago y no impago), lo que podría afectar la eficacia de los modelos predictivos.

- En ambos conjuntos de datos, la media de **RevolvingUtilizationOfUnsecuredLines** con 6.05% en entrenamiento y 5.3% en prueba, presenta una desviación estándar alta con 249.7 y 196.1, respectivamente. Además de valores máximos son elevados, con 50,708 y 21,821, respectivamente. Esto sugiere la existencia de prestatarios con un uso de crédito muy elevado, lo que refleja valores atípicos.
- En **Age**, la edad promedio de los prestatarios es similar en ambos conjuntos de datos, con un rango que se extiende desde 0 hasta 109 años en el conjunto de entrenamiento y desde 21 hasta 104 años en el conjunto de prueba. Precisamente una edad mínima de 0 años en el conjunto de entrenamiento podría indicar algunos errores de registro.
- Las tres variables **NumberOfTime** que representan las veces de retraso en el pago de la cuota según los intervalos entre días, demuestran que los valores máximos son altos (98 en todos los casos), lo que indica que algunos prestatarios tuvieron múltiples retrasos de más de un mes.
- El **DebtRatio** presenta una media y desviación estándar elevada en ambos conjuntos de datos, lo que sugiere que muchos prestatarios tuvieron deudas que superan sus ingresos mensuales, lo cual es un indicador de riesgo crediticio; o bien la presencia de estos valores relativamente altos reflejan la presencia de valores atípicos significativos.
- El **MonthlyIncome**, representando el ingreso mensual de los prestatarios, indica el promedio aproximado de \$6,670 en entrenamiento y \$6,855 en prueba. Sin embargo, existe una gran dispersión en los ingresos, con desviaciones estándar muy altas, con 14,384.7 en entrenamiento y 36,508.6 en prueba; y valores máximos que alcanzan cifras extraordinarias de hasta \$3,008,750 y \$7,727,000, respectivamente; lo que indica la presencia de prestatarios con ingresos muy altos que distorsionan la media.
- En **NumberOfOpenCreditLinesAndLoans**, el promedio de líneas de crédito y préstamos abiertos es de 8.45 en ambos conjuntos de datos, con un rango que va desde 0 hasta 58 en el conjunto de entrenamiento y hasta 85 en el conjunto de prueba.

- En **NumberOfDependents**, el promedio de dependientes en ambos conjuntos de datos sugiere que la mayoría de los prestatarios tienen pocos dependientes. Sin embargo, los valores máximos de 20 en entrenamiento y 43 en prueba, indica la existencia de prestatarios con un número elevado de dependientes, lo cual puede influir en la capacidad de pago como indicador relevante en el análisis de riesgo crediticio.

Tabla 3. Estadísticos descriptivos del conjunto de prueba

| Variable | Count | Mean | Std | Min | 25% | 50% | 75% | Max |
|--------------------------------------|--------|---------|----------|-----|-------|-------|-------|---------|
| RevolvingUtilizationOfUnsecuredLines | 101503 | 5,31 | 196,156 | 0 | 0,03 | 0,153 | 0,564 | 21821 |
| Age | 101503 | 52,405 | 14,78 | 21 | 41 | 52 | 63 | 104 |
| NumberOfTime30-59DaysPastDueNotWorse | 101503 | 0,454 | 4,538 | 0 | 0 | 0 | 0 | 98 |
| DebtRatio | 101503 | 344,475 | 1632,595 | 0 | 0,173 | 0,364 | 0,852 | 268326 |
| MonthlyIncome | 81400 | 6855,03 | 36508,6 | 0 | 3408 | 5400 | 8200 | 7727000 |
| NumberOfOpenCreditLinesAndLoans | 101503 | 8,454 | 5,144 | 0 | 5 | 8 | 11 | 85 |
| NumberOfTimes90DaysLate | 101503 | 0,297 | 4,516 | 0 | 0 | 0 | 0 | 98 |
| NumberRealEstateLoansOrLines | 101503 | 1,013 | 1,11 | 0 | 0 | 1 | 2 | 37 |
| NumberOfTime60-89DaysPastDueNotWorse | 101503 | 0,27 | 4,504 | 0 | 0 | 0 | 0 | 98 |
| NumberOfDependents | 98877 | 0,769 | 1,137 | 0 | 0 | 0 | 1 | 43 |

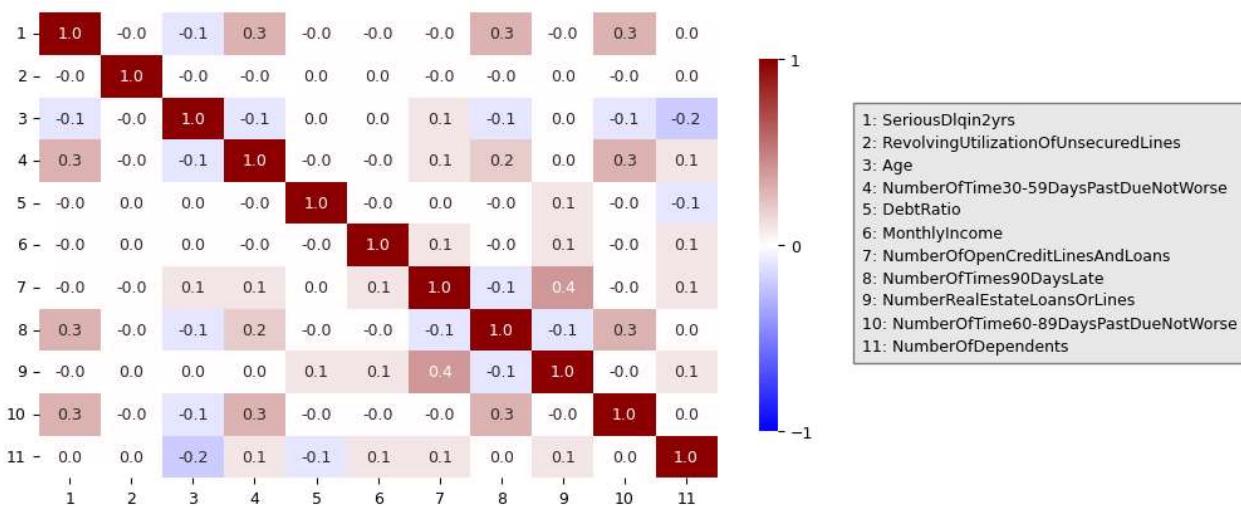
Fuente: Elaboración propia según resultados obtenidos con Python 3.12.1

En general, los datos originales presentan una considerable heterogeneidad, pues las variables contienen valores extremos con alta variabilidad, principalmente en el caso de la utilización de líneas de crédito, la relación deuda-ingreso y el ingreso mensual, lo que puede influir en los resultados predictivos de no ser realizado un tratamiento previo.

Se ha tomado como referencia el conjunto de datos de entrenamiento, con el fin de analizar la correlación entre variables (ver Gráfico 1). Los principales hallazgos revelan patrones significativos en el comportamiento de morosidad o impago (**SeriousDlqin2yrs**), donde se observa que la variable objetivo está fuertemente correlacionada con las tres variables que representan el número de veces que la persona ha estado retrasada en 30-59, 60-89, así como 90 días o más, en el pago de las cuotas. Esto sugiere que las personas que registran default tienden a experimentar

retrasos repetidamente en sus pagos en varios intervalos de tiempo. Además, se destaca una correlación negativa entre la edad y la cantidad de dependientes, indicando que las personas mayores generalmente tienen menos dependientes. También la correlación moderada positiva entre el número de líneas de crédito abiertas y el numero de préstamos hipotecarios y de bienes raíces, sugiere que aquellos con más líneas de crédito también tienden a tener más préstamos en bienes raíces.

Gráfico 1. Matriz de Correlación - Conjunto de Entrenamiento



Fuente: Elaboración propia usando Python 3.12.1

Por otro lado, en cuanto a la proporción relativamente baja de impagos del 6.7% con respecto al total de la variable, es previsible la posibilidad del conflicto en la modelización del riesgo de crédito al tener un desequilibrio considerable en el conjunto de datos, sugiriendo la necesidad de proponer técnicas especiales para manejar previamente la disparidad de clases. Problemáticas de este tipo en distintos contextos ya se han abordado previamente, pues de acuerdo con las evidencias de Gu *et al.* (2024) para el manejo de desequilibrios en los datos, mediante la integración del algoritmo Synthetic Minority Over-sampling Technique (SMOTE) con un modelo XGBoost, se demuestra que existe cierta sinergia entre ambas técnicas, al obtener ventajas en el rendimiento e incluso superando ligeramente a otras combinaciones de algoritmos en múltiples métricas de evaluación y por tanto influyendo en los resultados predictivos.

3.3. Tratamiento de Anomalías

La amplia dispersión de los datos, valores nulos y registros incorrectos enfatiza la importancia de realizar un preprocesamiento adecuado de los datos previo mediante el análisis exploratorio, con el fin de obtener resultados más precisos. En el preprocesamiento del conjunto original de entrenamiento y prueba, se comprueba la existencia de valores nulos en las variables de ingreso mensual y numero de dependientes, según se indica en la Tabla 2 y Tabla 3. De igual manera se detecta cantidades considerables de valores atípicos (outliers) en todas las variables. Profundizando en lo anterior, se han detectado valores atípicos extremos, que terminan por exceder la lógica del tipo de información financiera y/o sociodemográfica esperada en una base de datos para un problema relacionado al análisis de riesgo de crédito.

Para la identificación de valores atípicos, se ha implementado la técnica estadística del rango intercuartílico (IQR) que permite identificar valores extremos, donde cualquier valor fuera de este rango se considera un inusual, es decir, un valor que se desvía significativamente del resto del conjunto de datos.

$$IQR = Q3 - Q1$$

Donde **$Q1$** que corresponde al primer cuartil, definido como el valor que separa el 25% inferior de los datos, que con una distribución ordenada de n datos, puede encontrarse en la posición $\frac{n+1}{4}$. En cuanto a **$Q3$** corresponde al tercer cuartil, definido como el valor que separa el 75% inferior de los datos, que con una distribución ordenada de n datos, puede encontrarse en la posición $3 * \frac{n+1}{4}$. En cuanto a los límites superior e inferior, se establecen:

- Límite superior: $Q3 + 1.5 * IQR$
- Límite inferior: $Q1 - 1.5 * IQR$

Se ha aplicado esta técnica sobre ambos conjuntos de datos, con el fin de analizar a profundidad la distribución inusual de cada una de las variables. Se observa cierta similitud en la cantidad de este tipo de valores, tanto en el conjunto de entrenamiento (ver Tabla 4) como en el de prueba (ver Tabla 5), donde se destaca la variable de la relación deuda-ingreso, la cual presenta el mayor porcentaje de outliers en ambos conjuntos, sugiriendo una alta variabilidad con numerosos casos inusuales. Además, se logra identificar algunos casos extremos como lo es el registro de 329.664

relación deuda-ingreso.

En el mismo sentido, le sigue el retraso del pago del préstamo en cantidad de outliers, indicando que una parte significativa de los datos tiene múltiples retrasos en el pago dentro del rango de 30-59 días, lo que podría señalar un patrón problemático en los pagos, o bien registros inusuales del mismo. Ahora bien, en cuanto a anomalías extremas, los outliers extremadamente altos en el saldo total de tarjetas de crédito y líneas de crédito personales, lo que refleja un uso excepcionalmente alto y poco probable de distintas líneas crédito.

Tabla 4. Análisis de outliers. Conjunto de entrenamiento

| Variable | Media | Min | Max | Conteo | % |
|--------------------------------------|--------|---------|---------|--------|-------|
| RevolvingUtilizationOfUnsecuredLines | 6,0 | 1,4 | 50708 | 763 | 0,5% |
| Age | 52,3 | 0,0 | 109 | 46 | 0,0% |
| NumberOfTime30-59DaysPastDueNotWorse | 0,4 | 1,0 | 98 | 23982 | 16,0% |
| DebtRatio | 353,0 | 1,9 | 329664 | 31311 | 20,9% |
| MonthlyIncome | 6670,2 | 15523,0 | 3008750 | 4879 | 3,3% |
| NumberOfOpenCreditLinesAndLoans | 8,5 | 21,0 | 58 | 3980 | 2,7% |
| NumberOfTimes90DaysLate | 0,3 | 1,0 | 98 | 8338 | 5,6% |
| NumberRealEstateLoansOrLines | 1,0 | 6,0 | 54 | 793 | 0,5% |
| NumberOfTime60-89DaysPastDueNotWorse | 0,2 | 1,0 | 98 | 7604 | 5,1% |
| NumberOfDependents | 0,8 | 3,0 | 20 | 13336 | 8,9% |

Fuente: Elaboración propia según resultados obtenidos con Python 3.12.1

Para el ingreso mensual, aunque el porcentaje de outliers es relativamente bajo, los ingresos mensuales extremos reflejan casos con ingresos muy altos, que comparativamente con la media y el outlier más bajo en su respectivo conjunto, parece indicar a individuos con una capacidad económica muy superior a la esperada.

Otro caso destacable es con la edad, con valores inusualmente bajos o altos, pero más precisamente la edad 0 como el outlier mínimo identificado en el conjunto de entrenamiento. Estas principales anomalías se han revisado cuidadosamente para determinar si representan errores de entrada, casos extremos válidos, o patrones de comportamiento que requieren una atención especial en el análisis.

Tabla 5. Análisis de outliers. Conjunto de prueba

| Variable | Media | Min | Max | Conteo | % |
|--------------------------------------|--------|---------|---------|--------|-------|
| RevolvingUtilizationOfUnsecuredLines | 5,3 | 1,4 | 21821 | 493 | 0,5% |
| Age | 52,4 | 97,0 | 104 | 21 | 0,0% |
| NumberOfTime30-59DaysPastDueNotWorse | 0,5 | 1,0 | 98 | 16313 | 16,1% |
| DebtRatio | 344,5 | 1,9 | 268326 | 21018 | 20,7% |
| MonthlyIncome | 6855,0 | 15394,0 | 7727000 | 3368 | 3,3% |
| NumberOfOpenCreditLinesAndLoans | 8,5 | 21,0 | 85 | 2699 | 2,7% |
| NumberOfTimes90DaysLate | 0,3 | 1,0 | 98 | 5718 | 5,6% |
| NumberRealEstateLoansOrLines | 1,0 | 6,0 | 37 | 523 | 0,5% |
| NumberOfTime60-89DaysPastDueNotWorse | 0,3 | 1,0 | 98 | 5128 | 5,1% |
| NumberOfDependents | 0,8 | 3,0 | 43 | 9343 | 9,2% |

Fuente: Elaboración propia según resultados obtenidos con Python 3.12.1

Tras la detección de anomalías y el tratamiento adecuado de cada variable de forma individual en el conjunto de datos original, además de la exploración detallada de cada variable, es necesario proponer nuevas formas de análisis para obtener evidencia sobre si ciertos registros deben conservarse, descartarse o modificarse, considerando la naturaleza de cada variable en el contexto del análisis de crédito. Para este caso, se ha implementado la técnica de imputación de datos utilizando la media y la mediana, especialmente en el caso de variables con un alto número de valores atípicos y nulos. Se ha descartado la imputación a través del entrenamiento de un modelo de regresión, ya que comparativamente, el enfoque de imputación con la media o mediana ha generado mejores resultados. Además, se han eliminado o modificado registros en otros casos para minimizar posibles errores en la información registrada.

3.4. Impacto del Preprocesamiento

Se ha realizado un análisis comparativo utilizando diversas técnicas de Machine Learning aplicadas a distintas versiones de la misma base de datos (concretamente, al conjunto de datos de entrenamiento) con el fin de evaluar las ventajas del preprocesamiento. Los resultados han demostrado que un tratamiento adecuado de los datos tiene un impacto significativo en el rendimiento predictivo de los modelos. Para ello, se han comparado diferentes enfoques para

manejar datos nulos y atípicos, generando las siguientes versiones del conjunto de datos: eliminación directa de registros con datos nulos, imputación de datos nulos con la mediana, y una combinación de imputación con la mediana y eliminación de outliers basada en criterios específicos. Con el testeo de estas versiones, y usando de referencia algunas técnicas reconocidas como Random Forest, XGBoost, Neural Network y Support Vector Machine, evaluadas según la métrica AUC (Área Bajo la Curva ROC), se ha medido la capacidad de un modelo de clasificación para distinguir entre clases. Matemáticamente, se define como:

$$AUC = \int_0^1 TPR(t) d(FPR(t))$$

Donde:

- $TPR(t)$ es la Tasa Verdadera de Positivos (True Positive Rate) en el umbral t .
- $FPR(t)$ es la Tasa Falsa de Positivos (False Positive Rate) en el umbral t .

El AUC se calcula integrando el área bajo la curva ROC, que traza la relación entre TPR y FPR a diferentes umbrales de clasificación. También se puede interpretar como la probabilidad de que el clasificador asigne una puntuación más alta a una muestra positiva que a una muestra negativa:

$$AUC = P(\hat{Y}_{positivo} > \hat{Y}_{negativo})$$

Un AUC de 0.5 indica que el modelo no tiene capacidad discriminativa (es decir, es equivalente a una clasificación aleatoria), mientras que un AUC de 1.0 indica una clasificación perfecta. Los posibles resultados de la métrica AUC y su relación con el nivel de desempeño se detallan a continuación:

- Menor a 0.5: bajo desempeño (el modelo es peor que el azar).
- 0.5 - 0.7: desempeño regular (el modelo es ligeramente mejor que el azar).
- 0.7 - 0.8: buen desempeño (el modelo es significativamente mejor que el azar).
- 0.8 y 0.9: muy buen desempeño (el modelo es muy preciso).
- Mayor a 0.9: excelente desempeño (el modelo es casi perfecto).

Tabla 6. Impacto por modelo y enfoque de tratamiento

| Posición | Modelo | Enfoque de Tratamiento | AUC | Desv. Est. (\pm) |
|----------|----------------|---|--------|----------------------|
| 1 | Random Forest | Imputación con Mediana & Outliers Removidos | 0,8589 | 0,0068 |
| 2 | Random Forest | Imputación con Mediana | 0,8584 | 0,0073 |
| 3 | XGBoost | Imputación con Mediana | 0,8568 | 0,0063 |
| 4 | XGBoost | Imputación con Mediana & Outliers Removidos | 0,8559 | 0,0080 |
| 5 | Random Forest | Nulos Removidos | 0,8501 | 0,0049 |
| 6 | XGBoost | Nulos Removidos | 0,8456 | 0,0097 |
| 7 | Neural Network | Imputación con Mediana & Outliers Removidos | 0,6407 | 0,0977 |
| 8 | SVM | Imputación con Mediana & Outliers Removidos | 0,6240 | 0,0220 |
| 9 | SVM | Nulos Removidos | 0,5973 | 0,0238 |
| 10 | SVM | Imputación con Mediana | 0,5879 | 0,0417 |

Fuente: Elaboración propia según resultados obtenidos con Python 3.12.1

Los resultados (ver Tabla 6) muestran que el rendimiento de los modelos varía significativamente según la versión del conjunto de datos, con ganancias notables cuando se aplica un preprocesamiento minucioso, en contraste con la simple eliminación de registros, especialmente con la metodología de imputación de datos y remoción de outliers, que está relacionada con el análisis detallado de las variables. Según esto, el modelo RF registra un AUC de 0.8589 y un bajo desvío estándar de 0.0068, indicando un alto rendimiento y estabilidad; así como el modelo XGB que también mostró un rendimiento sólido con un AUC de 0.8559. En contraste, las versiones que solo utilizaron imputación con la mediana o la eliminación de registros con datos nulos resultaron en un rendimiento ligeramente inferior, aunque aún competitivo al implementar las mismas técnicas. Sin embargo, los modelos que no aplicaron un preprocesamiento detallado, como los que eliminaron registros con datos nulos, presentaron un rendimiento menor y una mayor variabilidad en el AUC, particularmente en el caso del modelo SVM.

Esto revela la importancia de un preprocesamiento minucioso, mediante el uso de técnicas de imputación y la eliminación de outliers basada en un análisis detallado de las variables, que no solo mejora la precisión del modelo, sino que también contribuye a una mayor estabilidad en los resultados y mejoran el rendimiento predictivo de los modelos de Machine Learning. Esto subraya que un enfoque integral en la preparación de datos es fundamental para desarrollar modelos robustos y eficientes en el análisis de crédito.

4. Metodología

En esta sección, se propone una combinación estratégica de métodos de optimización y técnicas de Machine Learning para mejorar la precisión de los modelos predictivos y asegurar interpretaciones robustas sobre la importancia de cada variable en la reducción del error del modelo. En particular, se ha decidido utilizar dos enfoques principales de optimización: el método de Búsqueda Local (BL) para la selección de variables y el método de Cross Entropy (CE), para la optimización de la precisión del modelo mediante la selección óptima de las variables a incluir. Estos enfoques se combinan con varias técnicas de Machine Learning que han demostrado un alto rendimiento en el análisis de riesgo y la calificación crediticia, los cuales se han seleccionado bajo el sustento de la revisión de la literatura realizada, que destaca estos métodos como los más efectivos en contextos similares.

Tanto el método de BL como de CE permitirán identificar de manera exhaustiva la combinación óptima de variables que minimizan el Error Cuadrático Medio (ECM) para los diversos métodos de Machine Learning seleccionados. Estos modelos no solo representan una diversidad de enfoques en la predicción, sino que nos permitirán también una comparación integral del impacto de cada variable en el rendimiento predictivo a través del ECM. Esta estrategia integrada de optimización y modelado garantiza que los resultados obtenidos sean tanto precisos como generalizables, proporcionando una base sólida para la evaluación del riesgo crediticio.

4.1. Algoritmo de Búsqueda Local

Es un algoritmo de optimización que se utiliza para encontrar una solución óptima dentro de un espacio de soluciones posibles. En nuestro caso, este enfoque se aplica para encontrar la combinación óptima de variables $x_1, x_2, x_3, \dots, x_n$ que minimizan el ECM de cada uno de los modelos predictivos M_i ($i = 1, \dots, 8$). Estos problemas responden a la siguiente formulación:

$$\min_X: ECM(X; M_i)$$

Donde $X = (x_1, x_2, x_3, \dots, x_n)$ es un vector binario que indica la inclusión ($x_k = 1$) o exclusión ($x_k = 0$) de la variable k en el modelo M_i , cuyo objetivo es predecir lo mejor forma posible la variable objetivo de tipo dicotómica que representa el default crediticio (**SeriousDlqin2yrs**). El

espacio de soluciones está definido por todas las combinaciones posibles de n variables, donde cada variable puede estar presente o ausente en el modelo:

$$S = \{X \mid X \in \{0, 1\}^n\}$$

Teniendo en cuenta lo anterior, el procedimiento del algoritmo de Búsqueda Local se constituye de los siguientes pasos:

- 1. Inicialización:** Selección de una solución inicial aleatoria $X_0 \in S$.
- 2. Evaluación:** Se calcula el ECM del modelo M_i con las variables seleccionadas por X_0 , denotado como ECM (X_0).
- 3. Generación de Vecinos:** Se crea un conjunto de soluciones vecinas $N(X_0)$ mediante la alteración de una única variable en X_0 , es decir, cuando su valor cambia de 0 a 1 o viceversa.
- 4. Selección de Mejora:** Se evalúa cada vecino en $N(X_0)$ y se selecciona la solución que minimiza el ECM de entre aquellas que tiene un ECM menor que X_0 .
- 5. Iteración:** Se actualiza la solución a la mejor solución vecina encontrada y se repiten los pasos 2 a 4, hasta que ninguna solución en $N(X_0)$ mejora el valor de ECM (X_0).

Finalmente, este procedimiento de 5 pasos se repite 10 veces.

4.2. Algoritmo de Cross Entropy

Este enfoque se basa en el remuestreo adaptativo para la optimización de combinaciones de variables binarias. Originalmente propuesto por Rubinstein (1997) para estimar probabilidades de eventos raros (Laguna *et al*, 2009), el método fue adaptado para problemas de optimización combinatoria, convirtiéndose en una técnica eficaz para resolver problemas en los que las soluciones se pueden representar como cadenas binarias. En el presente trabajo, aplicamos este método para encontrar la mejor combinación de variables que optimice el rendimiento de los modelos predictivos utilizados para la evaluación del riesgo crediticio. Es decir, utilizamos este método para resolver de nuevo el problema consistente en encontrar la combinación óptima de variables $x_1, x_2, x_3, \dots, x_n$ que minimizan el ECM de los modelos predictivos M_i ($i = 1, \dots, 8$). Estos problemas responden, de nuevo, a la siguiente formulación:

$$\min_X: ECM(X; \mathbf{M}_i)$$

Donde $X = (x_1, x_2, x_3, \dots, x_n)$ es un vector binario que indica la inclusión ($x_k = 1$) o exclusión ($x_k = 0$) de la variable k en el modelo \mathbf{M}_i , cuyo objetivo es predecir lo mejor posible la variable objetivo de tipo dicotómica que representa el default crediticio (**SeriousDlqin2yrs**). El espacio de soluciones está definido por todas las combinaciones posibles de n variables, donde cada variable puede estar presente o ausente en el modelo:

$$S = \{X \mid X \in \{0, 1\}^n\}$$

En este contexto, el método CE se utiliza para optimizar la selección de variables en los modelos de clasificación binaria mediante un proceso iterativo de mejora. En lugar de simplemente ajustar parámetros internos del modelo, como en su uso tradicional en problemas de clasificación, para este caso es empleado para encontrar las combinaciones de variables más efectivas que minimicen el error de predicción para cada modelo \mathbf{M}_i ($i = 1, \dots, 8$). Considerando lo anterior, el procedimiento que sigue el algoritmo corresponde a:

- 1. Generación de Muestras Aleatorias:** El proceso comienza generando una muestra de N soluciones aleatorias, donde cada variable tiene una probabilidad inicial de 0.5 de ser 1 (inclusión en el modelo) o 0 (exclusión). Este enfoque asegura que todas las variables tengan inicialmente la misma probabilidad de ser seleccionadas, pues no se asume ningún conocimiento previo sobre su relevancia.
- 2. Selección del Conjunto Élite:** Una vez generada la muestra de N soluciones, se evalúa el rendimiento de cada solución según el ECM. A partir de esta evaluación, se seleccionan las n mejores soluciones que se denominan el conjunto élite, y corresponden a las combinaciones de variables que mejoran el rendimiento del modelo.
- 3. Actualización de Probabilidades:** Basado en el conjunto élite, se recalculan las probabilidades de inclusión de cada variable. Para cada variable k , se recalcula la probabilidad de ser 1 (es decir, estar incluida en las mejores combinaciones) de la siguiente forma:

$$p_k = \frac{1}{n} \sum_{j=1}^n x_{k,j}$$

Donde $x_{k,j}$ corresponde al valor de la variable k en la j -ésima solución del conjunto élite. Este ajuste aumenta la probabilidad de que las variables más presentes en las mejores soluciones tengan mayor probabilidad de ser seleccionadas en la siguiente iteración.

- 4. Remuestreo:** Con las nuevas probabilidades actualizadas, se genera una nueva muestra de N soluciones aleatorias, utilizando las probabilidades modificadas, que junto con el conjunto élite de la iteración previa, se vuelven a evaluar, repitiendo el proceso de optimización.
- 5. Iteración del Proceso:** Los pasos de selección del conjunto élite y actualización de probabilidades se repiten hasta que se alcanza un número máximo de iteraciones $iter$. Este enfoque asegura que las combinaciones de variables se optimicen progresivamente, acercándose a una solución óptima que minimice el error de predicción.

Este proceso asegura que las combinaciones de variables converjan hacia aquellas que minimizan el error de predicción en el modelo de clasificación binaria, mejorando su precisión en la detección de riesgo crediticio. Los parámetros utilizados para este método son los siguientes:

- N : 75 (muestras aleatorias en cada iteración).
- n : 10 (tamaño del conjunto élite).
- $iter$: 15 (número de iteraciones).

4.3. Importancia de las Variables

En el método de BL, para cada modelo de Machine Learning, se genera una solución óptima en la que una variable toma el valor 1 si está incluida y 0 si no lo está. La importancia final de cada variable se calculará como la media de estos valores en todos los modelos.

El método CE, por su parte, optimiza la selección de variables para cada modelo de Machine Learning, identificando las variables más relevantes para mejorar el rendimiento predictivo del modelo, mediante la estimación de la probabilidad de que cada variable esté incluida en la solución óptima final. De esta forma, en el método CE una variable se considerará más importante si su probabilidad de estar incluida en la solución óptima final es mayor. Análogamente a como se hace

con el método de BL, la importancia final de cada variable se calculará como la media de estas probabilidades para todos los modelos.

5. Resultados

En esta sección, se presentan los resultados obtenidos de los modelos, mediante la aplicación de las técnicas de optimización de Búsqueda Local (BL) y Entropía Cruzada (CE), con cada una de las técnicas de Machine Learning seleccionadas, que corresponden a: Logistic Regression (LR), Random Forest (RF), Stochastic Gradient Descent (SGD), Bagged Decision Tree (BDT), Extreme Gradient Boosting (XGB o XGBoost), Support Vector Machines (SVM), K-Nearest Neighbors (KNN) y Redes Neuronales Artificiales (ANN). El objetivo del análisis de los resultados obtenidos se enfoca en tres aspectos principales:

1. Ganancia de precisión: Con base en el Error Cuadrático Medio (ECM), se evalúa el rendimiento de los modelos al incluir todas las variables frente al rendimiento tras la optimización. En muchos casos, añadir más variables no garantiza mayor precisión, e incluso puede reducirla debido al ruido generado por variables irrelevantes. Además, de acuerdo con el principio de parsimonia, un modelo con menos variables es preferible si ofrece el mismo nivel de error, no solo por ser más sencillo de interpretar, sino también por los costos asociados a la obtención de dichas variables.

2. Importancia de las variables:

- **Búsqueda Local (BL):** En cada modelo, BL genera una solución óptima en la que una variable toma el valor 1 si está incluida y 0 si no lo está. La importancia final de cada variable se calcula como la media de estos valores en todos los modelos.
- **Cross Entropy (CE):** En este caso, la importancia de una variable se mide como la probabilidad de que esté incluida en la solución óptima para cada modelo. Esta probabilidad se deriva de la distribución final generada por CE, y la importancia final de cada variable se obtiene como la media de estas probabilidades en los diferentes modelos.

3. Comparación de la importancia de las variables: Se comparan los resultados de ambos

métodos, BL y CE, para medir la importancia de las variables, permitiendo identificar patrones consistentes o diferencias entre los dos enfoques.

5.1. Modelos con Búsqueda Local

La Tabla 7 resume el rendimiento de los modelos en términos de ECM tras aplicar el algoritmo de BL. En ella se destaca la mejora obtenida para cada modelo al identificar la combinación óptima de variables, y se compara con la precisión del mismo modelo incluyendo todas las variables. En promedio, la optimización mediante BL reduce el ECM en un 0,253%, mejorando el desempeño de los modelos al identificar las variables más relevantes. Los resultados con mejor desempeño se obtienen con los modelos de RF, XGB y ANN, que corresponden a los tres mejores en el proceso de minimización el ECM. Así mismo, se encuentra también que estos dos primeros modelos evidencian un incremento considerablemente mayor en el nivel de mejora, con 0,350% y 0,425% respectivamente, aunque por encima de estos se encuentra el modelo BDT como el más beneficiado, al obtener una mejora del 0,675%. Por otro lado, se encuentra que el modelo SVM no experimentó mejora alguna con la optimización, es decir, la selección óptima de variables no permite eliminar ninguna de ellas del modelo.

Tabla 7. Análisis de ECM con BL

| Modelo | Todas las variables | Optimo | Mejora |
|--------------|---------------------|---------------|---------------|
| RF | 6,898% | 6,548% | 0,350% |
| XGB | 6,998% | 6,573% | 0,425% |
| ANN | 6,773% | 6,623% | 0,150% |
| BDT | 7,323% | 6,648% | 0,675% |
| SGD | 6,773% | 6,673% | 0,100% |
| LR | 6,773% | 6,698% | 0,075% |
| KNN | 7,023% | 6,773% | 0,250% |
| SVM | 6,798% | 6,798% | 0,000% |
| Media | 6,920% | 6,667% | 0,253% |

Fuente: Elaboración propia según resultados obtenidos con Python 3.12.1

Los resultados de la Tabla 8 muestran la importancia de cada variable con cada modelo de Machine Learning optimizado mediante la BL. Para poder comparar posteriormente con los resultados de CE, asignamos una importancia del 100% a una variable para un método si esa variable está en la solución óptima mediante la BL para ese modelo de Machine Learning, y una importancia del 0% en caso contrario. La importancia final de cada variable, tal y como se ha comentado, se obtiene como la media de estos valores para cada modelo. Se evidencia que las variables relacionadas a los comportamientos de pagos tardíos prolongados, principalmente cuando el estado de impago se encuentra desde los 60 y 90 días en adelante, indican ser los predictores más relevantes, al ser seleccionados en el 87.5% de las veces. Por su parte las variables como la edad, ingresos mensuales y numero de préstamos abiertos, son seleccionados por los modelos en un 50%, por lo que su relevancia es intermedia y varía según el modelo.

Tabla 8. Importancia de las variables con BL

| Variable | LR | RF | SGD | BDT | XGB | SVM | KNN | ANN | Media |
|--|------|------|------|------|------|------|------|------|--------------|
| NumberOfTimes-90DaysLate | 100% | 100% | 100% | 100% | 100% | 0% | 100% | 100% | 87,5% |
| NumberOfTime60-89DaysPastDueNotWorse | 100% | 100% | 100% | 100% | 100% | 0% | 100% | 100% | 87,5% |
| Age | 0% | 100% | 100% | 0% | 100% | 100% | 0% | 0% | 50,0% |
| MonthlyIncome | 100% | 100% | 0% | 0% | 100% | 0% | 100% | 0% | 50,0% |
| NumberOfOpenCredit-LinesAndLoans | 0% | 100% | 100% | 0% | 100% | 0% | 100% | 0% | 50,0% |
| NumberRealEstate-LoansOrLines | 0% | 0% | 100% | 100% | 0% | 100% | 100% | 0% | 50,0% |
| RevolvingUtilization-OfUnsecuredLines | 0% | 0% | 0% | 0% | 100% | 100% | 0% | 100% | 37,5% |
| DebtRatio | 100% | 100% | 0% | 0% | 0% | 100% | 0% | 0% | 37,5% |
| NumberOfTime30-59DaysPastDueNotWorse | 100% | 0% | 0% | 0% | 0% | 0% | 100% | 0% | 25,0% |
| NumberOfDependents | 0% | 100% | 0% | 0% | 0% | 0% | 0% | 0% | 12,5% |

Fuente: Elaboración propia según resultados obtenidos con Python 3.12.1

En análisis conjunto sugiere una relación directa entre los modelos que obtienen mejores resultados

al minimizar ECM y la selección de las variables que tienen mayor probabilidad de hacer parte de las combinaciones optimas. Los modelos RF, XGB, ANN y BDT, que muestran tanto los mejores óptimos como las mayores mejoras relativas en la optimización, seleccionan de manera consistente las variables relacionadas con los pagos tardíos los 60 y 90 días en adelante. Esto sugiere que la identificación de incumplimientos graves, exceptuando solo la situación de impago menor a 59 días, es clave para mejorar el rendimiento y la precisión predictiva del riesgo crediticio. Un aspecto clave considerando los resultados del modelo SVM, el cual presenta el más bajo desempeño, así como mejora en el proceso de optimización (ver Tabla 7), tiene que ver con que es el único modelo que no logra seleccionar las variables de pago tardío del préstamo, que son precisamente las más relevantes para la mayoría de los modelos, y en cambio considera dentro de su combinación optima, las variables de media y baja relevancia.

5.2. Modelos con Cross Entropy

La Tabla 9 resume el rendimiento de los modelos en términos de ECM tras aplicar el algoritmo de CE, y se compara con la precisión del mismo modelo incluyendo todas las variables. En promedio, los modelos optimizados con CE muestran una mejora del 0,266% en el ECM. Nuevamente, se evidencia que los modelos de RF, ANN y XGB, aunque con un ligero cambio en el orden, presentan el mejor desempeño en el proceso de minimización el ECM. En esta ocasión, el modelo SGD es el mayormente beneficiado, al obtener una mejora de 0,475%; seguido por XGB y BDT con 0,400% y 0.475% respectivamente. Esto sugiere que estos modelos, al ser altamente sensibles a la selección de variables, logran captar patrones importantes en la relación de las variables con el riesgo crediticio.

Al igual que con BL, el modelo SVM no muestra ninguna mejora con CE, lo que confirma que no responde bien a las optimizaciones de selección de variables para los enfoques propuestos. Sin embargo, este mismo modelo deja de presentar el más bajo rendimiento según los resultados de BL (ver Tabla 7), pero esto no es explicado porque obtenga un mayor optimo, sino porque los modelos de KNN y BDT empeoraron en el proceso de selección optima de variables al obtener un óptimo final considerablemente menor.

Tabla 9. Análisis ECM con CE

| Modelo | Todas las variables | Optimo | Mejora |
|--------------|---------------------|---------------|---------------|
| RF | 6,898% | 6,548% | 0,350% |
| ANN | 6,773% | 6,548% | 0,225% |
| XGB | 6,998% | 6,598% | 0,400% |
| SGD | 7,148% | 6,673% | 0,475% |
| LR | 6,773% | 6,698% | 0,075% |
| SVM | 6,798% | 6,798% | 0,000% |
| KNN | 7,023% | 6,823% | 0,200% |
| BDT | 7,323% | 6,923% | 0,400% |
| Media | 6,967% | 6,701% | 0,266% |

Fuente: Elaboración propia según resultados obtenidos con Python 3.12.1

Por su parte, la Tabla 10 muestra la importancia de cada variable en los diferentes modelos, donde esta importancia se mide como la probabilidad de que una variable esté incluida en la solución óptima final para cada modelo, tras su optimización mediante el método de CE. Los resultados demuestran que las variables más relevantes en CE son, nuevamente las relacionadas a los historiales de pagos tardíos prolongados, en general cuando el estado de impago es desde los 60 días en adelante. Esto reafirma la importancia de estas variables como predictores claves del riesgo crediticio, sin embargo, la probabilidad de ser seleccionadas disminuye con respecto a los modelos que se combinan con BL. Por su parte, el número de préstamos abiertos, la relación deuda-ingresos y el número de dependientes, muestran una importancia destacable que es igual o superior al 60%, sugiriendo que los modelos de CE logran beneficiarse de la información sobre estas variables.

Se destaca el aumento en la relevancia esperada del número de dependientes en los distintos modelos, ya que en BL es la variable con menor probabilidad de ser seleccionada. De hecho, parece alternar en importancia esperada con el número de préstamos abiertos, que también presenta una baja probabilidad de selección. Otras variables, como la edad, los ingresos mensuales y los pagos tardíos entre 30 y 59 días, mantienen una relevancia intermedia o baja, lo que sugiere que su inclusión varía según el modelo, mostrando un impacto limitado en la predicción del riesgo crediticio en CE.

Tabla 10. Importancia de las variables con CE

| Variable | LR | RF | SGD | BDT | XGB | SVM | KNN | ANN | Media |
|--|------|------|------|------|------|------|------|------|--------------|
| NumberOfTime60-89DaysPastDueNotWorse | 100% | 100% | 100% | 0% | 100% | 40% | 90% | 100% | 78,8% |
| NumberOfTimes-90DaysLate | 100% | 100% | 100% | 100% | 100% | 10% | 0% | 100% | 76,3% |
| NumberOfOpen-CreditLinesAndLoans | 0% | 100% | 100% | 100% | 100% | 0% | 90% | 0% | 61,3% |
| DebtRatio | 0% | 100% | 0% | 100% | 0% | 80% | 100% | 100% | 60,0% |
| NumberOfDependents | 100% | 100% | 0% | 100% | 0% | 80% | 100% | 0% | 60,0% |
| NumberRealEstate-LoansOrLines | 100% | 0% | 40% | 100% | 0% | 100% | 90% | 0% | 53,8% |
| Age | 0% | 100% | 90% | 100% | 0% | 10% | 90% | 0% | 48,8% |
| MonthlyIncome | 100% | 100% | 0% | 100% | 0% | 90% | 0% | 0% | 48,8% |
| NumberOfTime30-59DaysPastDueNotWorse | 100% | 0% | 100% | 0% | 0% | 10% | 0% | 0% | 26,3% |
| RevolvingUtilization-OfUnsecuredLines | 0% | 0% | 0% | 0% | 0% | 100% | 0% | 100% | 25,0% |

Fuente: Elaboración propia según resultados obtenidos con Python 3.12.1

Entre otros hallazgos, se observa que el modelo ANN mejora su rendimiento en CE, superando ligeramente a XGB al incluir en su combinación óptima la variable de relación deuda-ingreso, algo que no ocurre en los resultados conjuntos de los modelos con BL. Además, ANN parece ser más sensible a mejoras cuando se utiliza en combinación con CE que con BL, lo que sugiere que su capacidad de ajuste y rendimiento es más efectiva en este contexto.

5.3. Comparación Entre Enfoques

La comparación conjunta de los resultados se presenta en la Tabla 11, donde se encuentra que las variables relacionadas con los pagos tardíos prolongados, más precisamente los impagos presentados desde los 60 días y 90 en adelante, son consistentes y relevantes en ambos enfoques de optimización, destacándose como los predictores claves del riesgo crediticio. Esto es evidente por la alta media de importancia de estas variables, con una importancia media que supera el 80%, indicando que estas variables están presentes en la mayoría de los modelos optimizados.

Este hallazgo explica también el rendimiento relativamente bajo de BDT, SVM y KNN (ver Tabla 7 y Tabla 9) en ambos enfoques, pues en el proceso de optimización, estos modelos no logran generar combinaciones óptimas que incluyan estas variables relacionadas al comportamiento de pago. Esto es evidente por la alta media de importancia de estas variables, lo que indica que estas variables están presentes en la mayoría de los modelos optimizados.

Tabla 11. Importancia de variables entre BL y CE

| Variable | BL | CE | Diferencia (CE-BL) | Media |
|---|-------|-------|--------------------|-------|
| NumberOfTime60-89DaysPastDueNotWorse | 87,5% | 78,8% | -8,7% | 83,1% |
| NumberOfTimes90DaysLate | 87,5% | 76,3% | -11,3% | 81,9% |
| NumberOfOpenCreditLinesAndLoans | 50,0% | 61,3% | 11,3% | 55,6% |
| NumberOfRealEstateLoansOrLines | 50,0% | 53,8% | 3,8% | 51,9% |
| Age | 50,0% | 48,8% | -1,3% | 49,4% |
| MonthlyIncome | 50,0% | 48,8% | -1,3% | 49,4% |
| DebtRatio | 37,5% | 60,0% | 22,5% | 48,8% |
| NumberOfDependents | 12,5% | 60,0% | 47,5% | 36,3% |
| RevolvingUtilizationOfUnsecuredLines | 37,5% | 25,0% | -12,5% | 31,3% |
| NumberOfTime30-59DaysPastDueNotWorse | 25,0% | 26,3% | 1,3% | 25,6% |

Fuente: Elaboración propia según resultados obtenidos con Python 3.12.1

En los modelos optimizados con CE, las variables como la relación deuda-ingreso y el número de dependientes adquieren mayor relevancia en comparación con BL, lo que sugiere que CE captura patrones relacionales más complejos. Caso contrario se presenta con la variable del saldo total en tarjetas de crédito y líneas de crédito personales, pues registra la mayor perdida de importancia media de entre los modelos. Esto evidencia que BL tiende a una mayor rigidez, centrándose en variables relacionadas con impagos, mientras que CE ofrece una selección más flexible al incorporar variables adicionales. En general, los modelos mayormente beneficiados en el proceso de optimización, que corresponden a RF, XGB, ANN y BDT, dependen de las mismas variables clave, independientemente del enfoque.

Por otro lado, el modelo SVM no muestra mejoras significativas en ningún caso, sugiriendo la falta

de adaptabilidad a la selección de combinaciones óptimas de variables. En cuanto a la ganancia de precisión, los resultados muestran que la optimización con ambos enfoques permite mejorar el rendimiento de los modelos en la predicción del riesgo crediticio, donde CE supera ligeramente a BL en la mejora esperada entre los distintos modelos.

6. Conclusiones

El presente trabajo se centra en la exploración y aplicación de técnicas avanzadas de Machine Learning y Deep Learning para la evaluación y gestión del riesgo crediticio, utilizando datos de crédito al consumo. Se tiene como propósito, evaluar e identificar la combinación de algoritmos de optimización con técnicas de Machine Learning que brindan el mejor desempeño, así como las variables más relevantes que incrementan la precisión predictiva en el análisis del riesgo de impago crediticio. Además, se lleva a cabo una revisión de antecedentes de investigación que justifica el impacto de la Cuarta Revolución Industrial y la transformación digital sobre la toma de decisiones en el contexto económico y empresarial, a la vez de evidenciar el papel de las distintas disciplinas tecnológicas que se han generado en torno a los componentes clave del estudio de la Inteligencia Artificial, promoviendo la innovación en los procesos productivos.

Con la revisión de literatura, se ha demostrado la eficacia del Machine Learning en la gestión del riesgo crediticio, superando a los métodos tradicionales en precisión y reducción de pérdidas por impago. Algoritmos como RF y XGB se destacan por su rendimiento superior, mientras que modelos más complejos que integran la Deep Learning, como lo son las Redes Neuronales Profundas, ofrecen resultados ambiguos y se caracterizan por tener mayores costos computacionales y limitaciones en la interpretabilidad. Por otro lado, las técnicas basadas en Redes Neuronales Multicapa han revelado cómo el riesgo de impago se propaga entre agentes financieros interconectados, lo que ofrece nuevas perspectivas para la gestión preventiva del riesgo. Con esto, se evidencia en investigaciones más recientes, la tendencia por incursionar en enfoques alternativos para la evaluación del riesgo crediticio, que se basan no solo en la implementación de Deep Learning, sino en la incorporación de datos no financieros como las huellas móviles, sociales y digitales. Con este tipo de datos alternativos, se han encontrado mejoras significativas en la precisión predictiva del riesgo crediticio, superando incluso el desempeño de las técnicas de Machine Learning convencionales. La implementación de este enfoque a nivel productivo se

encuentra liderado por las FinTech y BigTech, y ofrece una visión más integral del perfil crediticio al incluir variables más allá de la información financiera tradicional, lo que contribuye a la inclusión financiera y bancarización de perfiles que carecen del historial crediticio tradicional.

En relación con el procesamiento previo de la información para la aplicación de técnicas de Machine Learning, se ha comprobado que el análisis minucioso de los datos, a través de la caracterización y tratamiento que sigue el enfoque de la imputación de valores nulos y eliminación de outliers, mejora notablemente el rendimiento predictivo, con el fin de obtener mayor estabilidad y precisión en los modelos. Partiendo de esto, la propuesta metodológica del presente trabajo se basa en la implementación de algoritmos de optimización de BL y CE, permitiendo la mejora significativa del rendimiento de los modelos predictivos. Según los resultados obtenidos se encuentra que, entre los modelos evaluados, las técnicas RF, XGB y ANN, obtienen las mayores mejoras en la minimización del ECM en el proceso de selección de combinaciones óptimas de variables. Por otro lado, las variables relacionadas con el comportamiento de pago crediticio, específicamente con el número de veces que el prestatario ha tenido un retraso reiterado en el pago de la cuota de entre 60 a 89, así como de 90 días en adelante, se destacan como las variables más relevantes en la mayoría de los modelos, y por lo tanto como factores fundamentales para la predicción del riesgo crediticio en ambos enfoques de optimización.

En el proceso de optimización, los modelos de RF, XGB, ANN y BDT fueron los mayormente beneficiados, esto según la diferencia calculada entre el óptimo de la evaluación conjunta con todas las variables y el obtenido en la combinación óptima de variables. De hecho, se evidencia que, independientemente del enfoque, estos modelos logran seleccionar en su óptimo las mismas variables relevantes. Incluso en el caso del modelo ANN, se encuentra que mejora notablemente su rendimiento en CE, superando ligeramente a XGB, al incluir variables clave como la relación deuda-ingreso, lo cual no ocurre en la optimización con BL. Esto resalta el valor de los enfoques dinámicos en la selección de variables para mejorar la precisión en la predicción del riesgo crediticio. Por el contrario, los resultados del modelo SVM en ambos enfoques, no refleja mejoras significativas, lo que sugiere falta de adaptabilidad a la selección óptima de variables en este contexto. A nivel general, se observó que la optimización con ambos enfoques, BL y CE, permitió mejorar el rendimiento predictivo, aunque CE superó ligeramente a BL en términos de ganancia de precisión.

Comparando entre los enfoques BL y CE, se evidencia que, aunque las variables relacionadas con los pagos tardíos prolongados son consistentes en ambos casos, el enfoque CE ofrece una visión más flexible al considerar información adicional de otras variables, principalmente de la relación deuda-ingreso y el número de dependientes. Estas variables adquirieron mayor relevancia en CE que en BL, sugiriendo que CE puede capturar relaciones complejas entre las variables. Mientras que BL tiende a ser más rígido en la selección de variables relacionadas con comportamientos de impago, CE demostró una mayor flexibilidad al considerar información adicional del contexto financiero. Esto hace que CE sea una herramienta más holística para la evaluación del riesgo crediticio, al integrar tanto factores históricos como actuales del perfil crediticio del prestatario.

Una de las principales limitaciones es la complejidad y falta de interpretabilidad de algunos modelos, como las Redes Neuronales Profundas, lo que plantea desafíos en términos de transparencia y aceptación regulatoria. También es importante abordar el riesgo de sesgo en los modelos predictivos, ya que se ha comprobado que la implementación no regulada de algoritmos entrenados con información limitada y mayormente sociodemográfica termina por influir negativamente en la concesión crediticia y por tanto la inclusión financiera. Esto puede derivar en generalizar la toma de decisiones sesgadas, basadas en predicciones discriminatorias que puede afectar principalmente a las poblaciones vulnerables y generar mayores desigualdades en la distribución del crédito. Ante esta problemática, el uso de datos no tradicionales, como huellas digitales y redes sociales, presenta una oportunidad para ampliar la inclusión financiera, a la vez de desarrollar inteligencia artificial explicable (XAI) para generar modelos más comprensibles y transparentes, lo cual puede ser un motivante para abordar este tipo de problemáticas en futuras investigaciones relacionadas.

7. Bibliografía

- ¿Cómo robustecer la gestión de riesgos a partir del Machine Learning? (2022, December 1). Aplicaciones de Inteligencia Artificial; AIS Group. <https://ais-int.com/como-robustecer-la-gestion-de-riesgo-de-credito-a-partir-del-machine-learning/>
- Agarwal, S., Alok, S., Ghosh, P., & Gupta, S. (2020). Financial Inclusion and Alternate Credit Scoring for the Millennials: Role of Big Data and Machine Learning in Fintech. <https://www.semanticscholar.org/paper/Financial-Inclusion-and-Alternate-Credit-Scoring-of-Agarwal-Alok/94f16759a0733267f03f59905a99def903dc4841>
- Agarwal, Sumit and Alok, Shashwat and Ghosh, Pulak and Gupta, Sudip, Financial Inclusion and Alternate Credit Scoring: Role of Big Data and Machine Learning in Fintech (December 21, 2019). Indian School of Business, Available at SSRN: <https://ssrn.com/abstract=3507827>
- Agencia Española de Protección de Datos (AEPD). (2019). Fingerprinting o Huella digital del dispositivo. AEPD. <https://www.aepd.es/guias/estudio-fingerprinting-huella-digital.pdf>
- Alonso-Robisco, A., & Carbo, J. M. (2023, May). Aprendizaje automático en modelos de concesión de crédito: oportunidades y riesgos. Análisis Financiero Y Big Data (Capítulo III); Funcas. <https://www.funcas.es/articulos/aprendizaje-automatico-en-modelos-de-concesion-de-credito-oportunidades-y-riesgos/>
- Asociación Española de Banca (AEB). (2019). El uso de la Inteligencia Artificial en el sector bancario. AEB. <https://s1.aebanca.es/wp-content/uploads/2019/07/la-inteligencia-artificial-en-el-sector-bancario.pdf>
- Banco de España. (2024, April 9). NOTA DE PRENSA . Banco de España; Banco de España. <https://www.bde.es/f/webbe/GAP/Secciones/SalaPrensa/NotasInformativas/24/presbe2024-28.pdf>
- Björn Rafn Gunnarsson, Seppe vanden Broucke, Bart Baesens, María Óskarsdóttir, Wilfried Lemahieu. (2021). Deep learning for credit scoring: Do or don't? European Journal of Operational Research, 295(1), 292-305. <https://doi.org/10.1016/j.ejor.2021.03.006>
- Caouette, J.B., Altman, E.I., Narayanan, P. and Nimmo, R. (2008) Managing Credit Risk: The Great Challenge for the Global Financial Markets. 2nd Edition, John Wiley & Sons, New York. <https://doi.org/10.1002/9781118266236>
- Chen, C., Lin, K., Rudin, C., Shaposhnik, Y., Wang, S., & Wang, T. (2018). An Interpretable Model with Globally Consistent Explanations for Credit Risk. ArXiv, abs/1811.12615. <https://arxiv.org/abs/1811.12615>
- Clements, J.M., Xu, D., Yousefi, N., & Efimov, D. (2020). Sequential Deep Learning for Credit Risk Monitoring with Tabular Financial Data. ArXiv, abs/2012.15330. <https://arxiv.org/abs/2012.15330>
- Posada Fishman, Simon. Comp stats group data project - final. (2018, diciembre 6). Kaggle.com; Kaggle. <https://www.kaggle.com/code/simonpfish/comp-stats-group-data-project-final/notebook>

- Cornelli, G., Frost, J., Gambacorta, L., Rau, R., Wardrop, R., & Ziegler, T. (2020). Fintech and big tech credit: a new database. BIS Working Papers, 887. <https://www.bis.org/publ/work887.htm>
- D. J. Hand, W. E. Henley, Statistical Classification Methods in Consumer Credit Scoring: A Review, Journal of the Royal Statistical Society Series A: Statistics in Society, Volume 160, Issue 3, September 1997, Pages 523–541, <https://doi.org/10.1111/j.1467-985X.1997.00078.x>
- Dastin, J. (2018, October 14). Amazon abandona un proyecto de IA para la contratación por su sesgo sexista. <https://www.reuters.com/article/idUSKCN1MO0M4/>
- Elena Dumitrescu, Sullivan Hué, Christophe Hurlin, Sessi Tokpavi. (2022). Machine learning for credit scoring: Improving logistic regression with non-linear decision-tree effects. European Journal of Operational Research, 297(3), 1178-1192. <https://doi.org/10.1016/j.ejor.2021.06.053>
- Fernández Domínguez, D., Ward, A., O'Dwyer, B., Price, D., Cronin, F., & Crimmins, N. (2023, September 29). Cuantificación de riesgos y toma de decisiones con ML. Grant Thornton; Risk & Advisory Services. <https://www.grantthornton.es/perspectivas/consultoria/cuantificacion-de-riesgos-y-toma-de-decisiones-con-ml>
- Fuster, Andreas and Goldsmith-Pinkham, Paul S. and Ramadorai, Tarun and Walther, Ansgar, Predictably Unequal? The Effects of Machine Learning on Credit Markets (June 21, 2021). Journal of Finance, Forthcoming, Available at SSRN: <https://ssrn.com/abstract=3072038>
- Giulio Cornelli, Jon Frost, Leonardo Gambacorta, P. Raghavendra Rau, Robert Wardrop, Tania Ziegler. (2023). Fintech and big tech credit: Drivers of the growth of digital lending. Journal of Banking & Finance, 148, 106742. <https://doi.org/10.1016/j.jbankfin.2022.106742>
- Give me some credit. (s/f). Kaggle.com. Recuperado el 18 de septiembre de 2024, de <https://www.kaggle.com/competitions/GiveMeSomeCredit/data>
- Gregory, I. (s/f). Kaggle-GiveMeSomeCredit: Kaggle Data Set - Give Me Some Credit. <https://github.com/DrIanGregory/Kaggle-GiveMeSomeCredit>
- Hermitaño Castro, J. A. (2022). Aplicación de Machine Learning en la Gestión de Riesgo de Crédito Financiero: Una revisión sistemática. Interfases, 15(015), 160-178. <https://doi.org/10.26439/interfases2022.n015.5898>
- I-Cheng Yeh, Che-hui Lien. (2009). The comparisons of data mining techniques for the predictive accuracy of probability of default of credit card clients. Expert Systems with Applications, 36(2, Part 1), 2473-2480. <https://doi.org/10.1016/j.eswa.2007.12.020>
- John Egan. (2021, September 11). What Is Consumer Credit? Experian. <https://www.experian.com/blogs/ask-experian/what-is-consumer-credit/>
- Khandani, Amir & Kim, Adlar & Lo, Andrew. (2010). Consumer Credit-Risk Models Via Machine-Learning Algorithms. Journal of Banking & Finance. 34. 2767–2787. 10.1016/j.jbankfin.2010.06.001. https://www.researchgate.net/publication/257211751_Consumer_Credit-Risk_Models_Via_Machine-Learning_Algorithms/citations

- Leder, B. (2023, August 24). How To Use ML for Credit Scoring & Decisioning. PhData. <https://www.phdata.io/blog/how-to-use-ml-for-credit-scoring-decisioning/>
- Leonardo Gambacorta, Yiping Huang, Han Qiu, Jingyi Wang. Gambacorta, L., Huang, Y., Qiu, H., & Wang, J. (2024). How do machine learning and non-traditional data affect credit scoring? New evidence from a Chinese fintech firm. *Journal of Financial Stability*, 73, 101284. <https://doi.org/10.1016/j.jfs.2024.101284>
- Maldonado, L. (2020). Inteligencia artificial en el sector financiero. In <https://aecconsultoras.com/wp-content/uploads/2020/10/Informe-EVERIS.pdf>
- Manuel Laguna, Abraham Duarte, Rafael Martí. Laguna, M., Duarte, A., & Martí, R. (2009). Hybridizing the cross-entropy method: An application to the max-cut problem. *Computers & Operations Research*, 36(2), 487-498. <https://doi.org/10.1016/j.cor.2007.10.001>
- María Óskarsdóttir, Cristián Bravo, Carlos Sarraute, Jan Vanthienen, Bart Baesens. The value of big data for credit scoring: Enhancing financial inclusion using mobile phone data and social network Analytics. *Applied Soft Computing*. Volume 74, 2019. Pages 26-39. ISSN 1568-4946. <https://doi.org/10.1016/j.asoc.2018.10.004>.
- Montalvo, J. G. (2014). El impacto del big data en los servicios financieros. *Papeles de economía española*, suppl.nuevos negocios bancarios, 43-58,75. Retrieved from <https://www.proquest.com/scholarly-journals/el-impacto-del-big-data-en-los-servicios/docview/1624969829/se-2>
- Nascimento Silva, Luiz Roberto. Caballo de Troya digital: la cuarta revolución industrial. Edicions de la Universitat de Lleida, 2023. https://jabega.uma.es/discovery/fulldisplay?context=L&vid=34CBUA_UMA:VUI&search_scope=MyInst_and_CI&tab=default&docid=alma991011038974604986
- Olano, M. (2024). Crédito al consumo: un segmento en crecimiento en medio de un descenso generalizado del crédito. In Banco de España. Banco de España. <https://www.bde.es/f/webbe/GAP/Secciones/SalaPrensa/IntervencionesPublicas/DirectoresGenerales/supervision/IIPP-2024-04-11-olano-es.or.pdf>
- Óskarsdóttir, M., & Bravo, C. (2021). Multilayer network analysis for improved credit risk prediction. *Omega*, 105, 102520. <https://doi.org/10.1016/j.omega.2021.102520>
- Ossa Giraldo, W., & Jaramillo Marín , V. (2021). Machine Learning para la estimación del riesgo de crédito en una cartera de consumo. Eafit.edu.co; Universidad EAFIT. <https://repository.eafit.edu.co/items/b56605a2-d3d2-4f86-9a39-cacc576c7ea9>
- Parisa Golbayani, Ionuț Florescu, Rupak Chatterjee. (2020). A comparative study of forecasting corporate credit ratings using neural networks, support vector machines, and decision trees. *The North American Journal of Economics and Finance*, 54, 101251. <https://doi.org/10.1016/j.najef.2020.101251>
- PricewaterhouseCoopers. (2023). From threat to opportunity: PwC's Global Risk Survey 2023. PwC. <https://www.pwc.com/gx/en/issues/risk-regulation/global-risk-survey.html>

- Richard Bookstaber & Dror Kenett. Bookstaber, R., & Kenett, D. (2016). Looking deeper, seeing more: A multilayer map of the financial system. Briefs 16-06, Office of Financial Research, US Department of the Treasury. <https://ideas.repec.org/p/ofr/briefs/16-06.html>
- Sáez Lara, C. (2020, December 22). El algoritmo como protagonista de la relación laboral. Un análisis desde la perspectiva de la prohibición de discriminación. Unirioja; ISSN 0213-0750, N° 155, 2020, págs. 41-60. <https://dialnet.unirioja.es/servlet/articulo?codigo=7801689>
- Shi, S., Tse, R., Luo, W., D'Addona, S., & Pau, G. (2022). Machine learning-driven credit risk: a systemic review. Neural Computing and Applications, 34(17), 14327–14339. <https://doi.org/10.1007/s00521-022-07472-2>
- Stefan Lessmann, Bart Baesens, Hsin-Vonn Seow, Lyn C. Thomas. (2015). Benchmarking state-of-the-art classification algorithms for credit scoring: An update of research. European Journal of Operational Research, 247(1), 124-136. <https://doi.org/10.1016/j.ejor.2015.05.030>
- Universidad Politecnica de Madrid. (2022). ML aplicado al Riesgo de Crédito: construcción de modelos explicables. Newsletter Trimestral; Catedra iDANAE. <https://blogs.upm.es/catedra-idanae/wp-content/uploads/sites/698/2022/10/Idanae-3T22.pdf>
- Víctor García-Vaquero & Francisco Alonso, 2011. El crédito comercial en España: importancia relativa y evolución reciente. Boletín Económico, Banco de España, issue FEB, pages 67-77, febrero. <https://ideas.repec.org/a/bde/joures/y2011i02n05.html>
- Yiping Huang, Zhenhua Li, Han Qiu, Sun Tao, Xue Wang, Longmei Zhang. (2023). BigTech credit risk assessment for SMEs. China Economic Review, 81, 102016. <https://doi.org/10.1016/j.chieco.2023.102016>
- Yong Shi, Yi Qu, Zhensong Chen, Yunlong Mi, Yunong Wang. Improved credit risk prediction based on an integrated graph representation learning approach with graph transformation. European Journal of Operational Research, Volume 315, Issue 2, 2024. Pages 786-801. ISSN 0377-2217. <https://doi.org/10.1016/j.ejor.2023.12.028>.
- Zhouyi Gu, Jiayan Lv, Bingya Wu, Zihui Hu, Xinwei Yu. (2024). Credit risk assessment of small and micro enterprise based on machine learning. Heliyon, 10(5), e27096. <https://doi.org/10.1016/j.heliyon.2024.e27096>